

国内图书分类号：TP183

国际图书分类号：004.8

学校代码：10463

密级：□

河南工业大学
硕 士 学 位 论 文

面向粮食仓储的密集状态小麦
质量实时检测方法

作 者 姓 名 范嘉伟

指 导 教 师 吴兰 教授

学 位 门 类 工学

专 业 控制科学与工程

研 究 方 向 机器视觉

培 养 单 位 电气工程学院

完 成 时 间 二〇二五年四月

国内图书分类号：TP183
国际图书分类号：004.8

密级：公开

面向粮食仓储的密集状态小麦质量 实时检测方法

学 号 2022920298

作 者 姓 名 范嘉伟

指 导 教 师 吴兰 教授

申请学位级别 硕士

专 业 控制科学与工程

研 究 方 向 机器视觉

培 养 单 位 电气工程学院

论文答辩日期 二〇二五年五月二十二日

Classified Index: (TP183)

U.D.C: (004.8)

Henan University of Technology

Master Degree Thesis

Real-time Wheat Quality Detection Method for Dense State in Grain Storage

Student Number: 2022920298

Candidate: Fan Jiawei

Supervisor: Prof. Wu Lan

Academic Degree Applied for: Master

Speciality: Control Science and Engineering

Affiliations: School of Electrical Engineering

Dissertation Defense Date: May 22, 2025

摘 要

小麦作为我国重要的粮食作物之一，在仓储过程中对小麦质量的实时监测是保障储备安全的重要手段。传统离线检测的方式因其存在非及时性，使储麦品质问题发现滞后，导致储麦整体品质劣变。对储麦品质进行在线检测与预测，不仅可以实时感知储麦品质变化，也可作为反馈手段调控储藏策略，因此提高储麦品质在线检测与预测的精度具有重要意义。

轻量化检测算法虽具有较好的实时性，但由于其特征提取网络结构精简，导致模型难以有效提取不完善粒相关特征，存在漏检率高、精度低的缺陷。此外，现阶段预测方法受到储麦理化数据量与依赖超参数设置的影响，导致理化指标预测值与实际值的高误差。为减少小麦仓储过程中的品质损耗，实现对仓储过程中的品质监测，本文对小麦仓储过程中储麦品质的在线检测、预测方法展开研究，主要研究内容如下：

（1）针对轻量化模型在储粮外观品质的在线检测任务中存在高漏检率与低精度的问题，本文提出了一种基于轻量化网络模型的检测方法：首先，增加小目标检测层提升语义信息利用率，其次嵌入基于指数思想优化的 SENet 注意力机制模块，由此设计增强特征提取网络（Increase-FPN）提升模型在复杂背景中对不完善颗粒的特征提取能力，提高检测精度并降低漏检率，最后以深度可分离卷积作为主干部分残差网络的特征提取方式，减少了模型的参数量，优化模型部署并解决了实时性差的问题。实验表明本章所提出的改进算法 IDS-YOLO 在检测速度和检测精度之间达到了平衡，相比于其他对比算法模型的 mAP（mean Average Precision）值平均提升了 6.2%；FPS 值达到每秒 88 帧，满足实时检测的要求，改进后模型参数量大小仅有 5.5M。

（2）针对小麦生理生化指标样本稀缺导致的储麦品质指标预测误差较大的问题，本文提出了基于原数据特征提取的样本扩容方法，构造原始数据特征提取器，得到生理生化指标原始数据特征向量，并将特征向量与随机噪声结合，解决了生成数据单一的问题。在判别器判别过程中，采用对抗损失与特征匹配损失的联合损失方法，指向性的选择特征分布与原始数据具有相似性的生成数据。改进后 Feature-GAN 生成数据与原始数据在四项指标中的平均 KL 散度值为 0.0028，低于 GAN 模型，实验结果表明 Feature-GAN 生成数据与原始数据具有相似的特征分布，Feature-GAN 模型的生成数据

有效解决了小麦生理生化指标样本稀缺问题。

(3) 针对不同储藏环境造成指标变化呈现非平稳性的问题, 本文使用增容数据作为源域数据, 训练 LSTM 预训练权重, 并通过迁移学习的方式将储麦生理生化指标的复用特征嫁接于不同的储麦指标预测任务中。应用该策略的 TL-LSTM 模型在生理生化指标的预测任务中, 四项指标的平均 MAPE 值为 2.72%, 相比于单一 LSTM 模型平均 MAPE 值下降了 1.67%, 表明 TL-LSTM 在预测任务中有着更低的误差。针对储藏环境多因素耦合下导致指标变化多变性, 在使用迁移学习的基础上, 引入淘金热优化算法, 解决 LSTM 训练时依赖人工设定超参数干扰模型预测效果的问题。引入柯西高斯混合分布并结合自适应优化策略提高模型的拟合能力。实验结果表明, 本文所提出的 TL-CGGRO-LSTM 模型的 MAE、 R^2 、RMSE 三项指标平均值分别为 0.3765、0.9599、0.4376, 均优于其他对比模型。表明 TL-CGGRO-LSTM 模型具有高拟合、低误差的特性, 更适应储麦生理生化指标预测任务。

关键词: 储麦品质; 轻量化检测模型; 生成对抗网络; 深度学习; 迁移学习

Abstract

As one of China's critical grain crops, real-time monitoring of wheat quality during storage is essential for ensuring reserve safety. Traditional offline detection methods suffer from delayed identification of quality issues due to their non-real-time nature, leading to overall quality deterioration. Online detection and prediction of stored wheat quality not only enable real-time perception of quality changes but also serve as feedback for adjusting storage strategies, making it crucial to improve the accuracy of online detection and prediction.

Although lightweight detection algorithms exhibit favorable real-time performance, their simplified feature extraction network structures struggle to effectively capture features related to defective kernels, resulting in high missed detection rates and low precision. Furthermore, current prediction methods are constrained by limited physicochemical data and reliance on hyperparameter tuning, leading to significant deviations between predicted and actual physicochemical indicators. To mitigate quality losses during wheat storage and achieve real-time monitoring, this study investigates online detection and prediction methods for stored wheat quality. The main contributions are as follows:

(1) To address the high missed detection rate and low accuracy of lightweight models in online detection of grain appearance quality, a lightweight network-based detection method is proposed. First, a small target detection layer is added to enhance semantic information utilization. Second, an SENet attention mechanism module optimized via an exponential strategy is embedded, and an enhanced feature extraction network (Increase-FPN) is designed to improve the model's ability to extract features of defective kernels in complex backgrounds, thereby boosting detection accuracy and reducing missed detections. Finally, depthwise separable convolutions are employed in the residual network backbone to reduce model parameters, optimize deployment, and resolve real-time performance issues. Experiments demonstrate that the proposed IDS-YOLO algorithm achieves a balance between detection speed and accuracy, with a 6.2% average improvement in mAP (mean Average Precision) compared to other models. The model achieves 88 FPS, meeting real-time requirements, while maintaining only 5.5M parameters.

(2) To mitigate prediction errors caused by scarce physiological and biochemical indicator samples, a sample expansion method based on raw data feature extraction is proposed. A raw data feature extractor is constructed to derive feature vectors of physiological and biochemical indicators, which are then combined with random noise to diversify generated data. During discriminator evaluation, a joint loss function combining adversarial loss and feature matching loss is adopted to selectively retain generated data with feature distributions similar to the original data. The improved Feature-GAN achieves an average Kullback-Leibler (KL) divergence of 0.0028 across four indicators, outperforming standard GANs. Results confirm that Feature-GAN-generated data exhibit feature distributions consistent with raw data, effectively resolving sample scarcity.

(3) To address the non-stationary characteristics of indicator changes under varying storage environments, expanded data are used as source-domain data to train LSTM pre-trained weights. Transfer learning is applied to adapt reusable features of physiological and biochemical indicators to different prediction tasks. The TL-LSTM model achieves an average mean absolute percentage error (MAPE) of 2.72% across four indicators, with a 1.67% reduction in MAPE compared to standalone LSTMs, demonstrating superior prediction accuracy. To handle the complexity of multi-factor environmental coupling, a Cauchy-Gaussian mixture distribution and adaptive optimization strategy are introduced alongside the Gold Rush Optimizer (GRO) algorithm, reducing reliance on manual hyperparameter tuning. Experimental results show that the proposed TL-CGGRO-LSTM model achieves average MAE, R^2 , and RMSE values of 0.3765, 0.9599, and 0.4376, respectively, outperforming other models. This confirms its high adaptability and low-error characteristics for predicting physiological and biochemical indicators in stored wheat.

This study provides a robust framework for real-time quality monitoring and prediction in wheat storage, balancing efficiency, accuracy, and generalizability across complex storage conditions.

Key words: Stored wheat quality; Lightweight detection model; Generative adversarial networks; Deep learning; Transfer learning

目 录

1 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	3
1.2.1 不完善粒检测的国内外研究现状.....	3
1.2.2 储麦品质预测的国内外研究现状.....	6
1.3 本文研究内容.....	8
1.4 本文组织结构.....	10
1.5 本文数学符号阐述.....	11
2 相关技术与理论分析	15
2.1 目标检测相关技术.....	15
2.1.1 卷积神经网络.....	15
2.1.2 目标检测算法.....	15
2.1.3 SSD 检测算法	16
2.1.4 YOLOV3 检测算法	17
2.1.5 YOLOV4-Tiny 检测算法	18
2.2 粮堆表面不完善粒检测任务需求分析	19
2.3 基于轻量化模型的粮堆表面不完善粒检测过程	19
2.4 储麦生理生化指标预测相关技术	20
2.4.1 循环神经网络.....	20
2.4.2 数据增强.....	21
2.4.3 迁移学习.....	21
2.5 储麦生理生化指标变化趋势分析	22
2.6 储麦生理生化指标预测过程	24
2.7 本章小结.....	24
3 基于轻量化模型的粮堆表面不完善粒检测	27
3.1 引言.....	27
3.2 数据集制作及模型选择.....	27
3.2.1 实验所用数据集.....	28
3.2.2 模型选择.....	29
3.3 改进 YOLOV4-Tiny 模型.....	30
3.3.1 整体改进思路.....	30
3.3.2 注意力机制的优化.....	30
3.3.3 多特征提取模块的构建.....	32
3.3.4 模型轻量化改进.....	34

3.4 实验环境及模型评价指标	36
3.4.1 实验环境.....	36
3.4.2 模型评价指标.....	36
3.5 实验结果与模型评估.....	37
3.5.1 消融实验.....	37
3.5.2 不同模型参数的比较.....	40
3.5.3 不同模型训练结果的比较.....	41
3.6 本章小结.....	45
4 基于 Feature-GAN 的储麦品质数据扩容方法	47
4.1 引言.....	47
4.2 生成对抗网络模型.....	47
4.3 生成对抗网络模型的优化	49
4.3.1 生成器优化.....	49
4.3.2 判别器优化.....	50
4.4 储麦品质数据预处理.....	51
4.5 储麦品质数据增容结果分析	52
4.5.1 储麦品质数据相关性评估标准.....	52
4.5.2 数据相关性可视化.....	53
4.6 本章小结.....	54
5 基于迁移学习和改进淘金热算法优化 LSTM 的生理生化指标预测方法	57
5.1 引言.....	57
5.2 基于迁移学习的储麦生理生化指标预测方法	57
5.2.1 长短时记忆网络.....	57
5.2.2 储麦生理生化指标的特征复用.....	59
5.3 迁移学习效果分析.....	60
5.3.1 实验环境.....	60
5.3.2 预训练模型选取.....	61
5.3.3 实验结果分析.....	61
5.4 基于改进淘金热优化算法的 LSTM 模型.....	62
5.4.1 淘金热(GRO)优化算法	62
5.4.2 柯西高斯混合分布.....	64
5.4.3 淘金热算法的自适应优化.....	65
5.5 实验结果分析.....	67
5.5.1 模型评价指标.....	67
5.5.2 不同模型训练结果对比.....	68
5.6 本章小结.....	70
总结与展望.....	72

论文总结.....	72
论文展望.....	72
参考文献.....	74

1 绪论

1.1 研究背景与意义

民以食为天，食以安为先。小麦作为我国最重要的主食之一^[1]，其储备安全直接关系到社会稳定与国家战略。据国家统计局最新统计数据显示，2024 年我国粮食产量相比去年稳步增长，其中小麦产量为 2802.0 亿斤，相比去年增长 70.2 亿斤。新中国成立开始，中国粮食产量仅为 1.13 亿吨，到 2024 年我国粮食总产量达到了 1.4 万亿斤。粮食产量 12 倍的增长也表明我国实现了“吃不饱”到“吃得饱”的质变^[2]，完成了单一产量的提升^[3]。

随着我国经济和工业化的快速发展，小麦已从传统主食原料转型升级为食品工业的核心基础原料，在国民膳食结构中占据着愈发重要的战略地位^[4]。小麦品质是否优劣不仅直接决定着面粉加工食品的筋道口感与组织结构^[5]，而且通过蛋白质含量、颗粒硬度、吸水性等关键指标影响着面包的松软度、面条的弹性、饼干的酥脆度等终端食品品质^[6]。这种品质的递进式传导机制，使得我国消费者在实现“吃得饱”的基本需求后，正加速向“吃得好、吃得健康”的消费升级转型^[7]。因此，对储麦品质的检测与生理生化指标的预测是保障人民饮食需求的必要手段^[8]。

小麦质量品质的健康与否与小麦颗粒外表饱满有着直接的联系^[9]。根据国家标准规定，不完善粒是指受到损伤但尚有使用价值的小麦颗粒，包括虫蚀粒、破损粒、生芽粒、黑胚粒、和生霉粒。在粮食仓储中，这些不完善粒是造成粮食损耗的主要原因之一，其特征与产生的不利影响如表 1-1 所示。

小麦不完善粒主要由人为管理、害虫啃食、自身代谢损耗产生^[10]。在粮仓的日常管理中，需要对小麦进行出入库操作以完成相应的等级评定，在出入库过程中，机械仪器操作不合理以及被器械碾压导致小麦颗粒的破损^[11]。并且在入库前的小麦清理环节，如清理机器的效率不足、机器本身携带杂质，则会间接加剧小麦仓储期间霉变的概率^[12]。害虫啃食则为小麦不完善粒最主要、最复杂的产生方式。玉米象、谷蠹等储粮害虫在温度范围(28-32℃)、湿度范围(70%-75%)的适宜环境中，繁殖周期急剧缩短到 18 天^[13]。玉米象成虫的产卵方式是通过在小麦籽粒表面钻取空洞进行产卵，后玉米象幼

虫对籽粒内部的营养物质进行吸食，造成籽粒质量减轻^[14]。因此对储藏过程中小麦不完善粒的检测，是保证储备安全的重要反馈手段^[15]。先前，不完善粒的主要检测方式为定期离线检测，此种方式导致储麦品质问题发现滞后。因此，在短时间间隔中采用粮食无人机对储麦进行在线检测，可提高储麦品质监测的效率。

表 1-1 不完善粒种类及其危害

种类	外观特征	影响危害
虫蚀颗粒	表面多有虫蚀孔洞	加工制品异味，颜色变暗，品质劣变
破损颗粒	形状呈现破碎、压扁的状态	易黏附霉菌，易发热，增加害虫危害几率
生芽颗粒	胚部种皮破裂，芽根突破种皮	容易引发粮堆发热、霉变
黑胚颗粒	胚部呈黑色或褐色并伴有皱缩状	携带毒性，影响加工
生霉颗粒	胚部出现霉斑，面积大小不一	食用品质显著下降

小麦不完善粒是储麦仓储过程中受到储备环境和自身代谢导致的结果，由于小麦质量劣变速率较慢，所以不完善粒的产生时间阶段相对滞后^[16]。为了防患于未然，需要准确预测小麦生理生化指标的变化趋势，并根据小麦生理生化指标的变化调整储藏策略，是提高储麦质量的关键。

小麦储备前期阶段，各项生理生化指标受到小麦温度场、湿度场、生物场以及自身呼吸速率活跃因素的耦合影响，变化趋势随时间呈现非平稳性^[17]。温度场与湿度场的耦合使小麦在储备阶段容易发生湿热循环，造成脂肪酸酶的活性增高。当温度处于适宜范围时，微生物和害虫的活动变得活跃加剧了储麦霉变的风险^[18]。而粮堆中小麦籽粒由于堆叠以及自身呼吸代谢作用，使粮堆内部产生温度差，造成水分迁移现象^[19]。粮食储存期间水分过多是引起粮食颗粒霉变的重要因素。除此之外，过氧化物酶、电导率、脂肪酸值等生理生化指标的变化趋势会随着温度湿度的相互作用而改变。通过对小麦生理生化指标的准确预测，可对小麦储藏过程中调整储藏策略提供快速有效的依据。储麦生理生化指标的劣变首先会导致粮仓储藏整体环境的降低，诸如尿素酶等生理生化指标在超过安全范围后，会使蛋白质加速分解，并且在其储藏区域持续影响其他储麦的质量^[20]。诸如蛋白质等营养指标的改变，使小麦籽粒丧失了营养价值，也会影响种子后续的种植价值。其次，储麦品质的降低直接影响小麦的加工品质，导致小麦

在加工过程中产生面筋性能衰退、面制品口感衰败等问题^[21]。上述问题的产生，最终降低了储麦品质，使其只能作为饲料加工的原材料，其经济价值也受到了严重的影响。

在仓储前期，储麦生理生化指标检测方法依然面临着诸多技术瓶颈。第一，小麦仓储过程中环境复杂多变，检测设备的性能以及系统稳定性易受到储麦环境的噪声干扰。第二，现有评价方法仅围绕单点状态进行间断性离线检测，导致生理生化指标变化趋势缺乏时序性关联，也无法呈现储麦品质的变化规律。并且单点检测忽视了储麦各指标前期状态的积累效应对品质的影响。针对上述问题，需要构建多点、长时序的储麦生理生化指标预测体系。为实现储麦生理生化指标的精准预测，本文将以储麦为基础开展储麦数据扩容、特征复用、生理生化指标预测的研究方法。

1.2 国内外研究现状

1.2.1 不完善粒检测的国内外研究现状

小麦不仅是全球产量第三的农作物，也是世界各国的重要战略资源。小麦的战略价值使各国学者将其作为重要的研究对象。为了检测小麦中的不完善粒，可以利用 X 射线采集麦粒的二维投影，进而对麦粒进行三维重建，全方位观察麦粒的表面特征和内部结构，不过现在还需要找寻更有效的重建方法。高光谱设备可以检测小麦籽粒多个波段的光谱与反射率数据并进行整合，从而对小麦不完善粒进行识别，但所需数据量大，仪器成本昂贵等问题无法避免。

计算机技术的兴起，利用计算机对小麦特征进行提取并通过特征工程完成对小麦等谷物的分类识别成为学者研究的重点工作。Zayas^[22]对软东红、硬红东两组小麦图像使用判别函数进行规范分析，实验证明通过对小麦图像进行分析可以对两组小麦进行正确分类。Neuman^[23]等学者对全种类小麦进行图像分析，并根据籽粒的特性对小麦品种的分类情况进行比较，对其中 4 个硬粒东小麦的分类情况较好，其他品种小麦的正确率在 15%到 96%之间。Paliwal^[24]等对加拿大西部琥珀硬粒、红春小麦、黑麦等五类谷物的高分辨率图像进行破碎特征的提取。提取特征包括形态、纹理和颜色，总计 203 处特征。使用神经落网算法对其进行分类，结果显示对特征明显的谷物分类准确性达到了 90%，但部分谷物由于具有相似性特征对分类任务产生了干扰。学者 Liu^[25]等，为了实现 6 种水稻种子的准确分类，建立了一种基于颜色和形态特征的图像分析算法，

对水稻的 14 种颜色特征和 7 种外观形态特征进行分析并判断。实验表明, 6 种水稻的判别准确率在 80%到 90%之间。学者王志军^[26]为了完成对小麦籽粒外观评价任务, 使用 BP 算法综合使用了计算机视觉、小麦图像特征, 通过提取 12 个外观特征、12 个色泽纹理特征参数并输入到人工神经网络中进行学习。结果表明对小麦的外观评价准确率达到 93%。学者 Choudhary^[27]通过使用扫描相机提取小麦籽粒的形态学、纹理、质地等特征, 每个籽粒的特征都被全面的提取, 包括 51 个形态特征、93 个颜色特征、56 个纹理特征。并使用统计学分类的方法对小麦籽粒进行分类, 结果表明分类准确率达到 99.4%。学者 Singh^[28]为了识别虫蚀粒, 使用近红外与高光谱结合的方式对虫蚀粒与健康籽粒的彩色成像进行系统扫描, 将提取到的 230 个特征输入到反向神经网络。结果表明, 健康籽粒与虫蚀粒的分类结果分别达到了 96.4%和 91%。樊超^[29]通过在神经网络的训练过程中, 增加小麦的 5 个纹理特征, 结果表明, 纹理特征的增加使神经网络的识别准确率提高了 5.53%, 并对四种小麦进行有效识别。学者 Pourreza^[30]在稳定光照的情况下对小麦的灰度图像进行采集, 并以灰度共现矩阵、灰度游程矩阵、局部相似性三个等级从灰度图中提取了 131 个纹理特征, 使用线性判别分析法对小麦进行分类, 分类精度达 98.15%。张玉荣^[31]的研究中, 采用了 PCA 方法对 54 个特征参数进行降维处理, 这些参数是从完善粒、破损粒、病斑粒、生芽粒和虫蚀粒的特征中提取的, 并作为 BP 神经网络的输入。实验结果显示, 该方法在不完善粒的识别上取得了 93%的平均准确率, 为多种不完善粒的识别提供了一种有效的解决方案。

学者 Ebrahimi^[32], 引入机器视觉对小麦种子与小麦籽粒进行分类, 将 52 个形态与质地特征输入 ANN 网络模型。实验结果为, 小麦种子、小麦籽粒类别的分类准确率分别为 96.25%、87.50%。学者 Olgun^[33]研究了基于支持向量机模型的自动分类系统, 并使用 k-means 聚类方法对特征直方图内的 DSIFT 特征进行提取, 将小麦图像转换为特征直方图, 构成训练所需的数据集。使用支持向量机对小麦籽粒进行分类, 分类准确率为 88.33%。虽然机器学习方法在小麦不完善粒的分类任务中展现了较优的性能, 但通常伴随人工特征提取以及高昂数据标注代价的依赖, 限制了该方法在外观品质快速准确评估工作中的应用。人工特征的提取受到耗费大量人力与个体先验知识的影响, 这些因素制约了该技术的实用性和效率。

随着深度学习技术的发展和硬件需求的满足使卷积神经网络得以构建, 卷积神经网络的出现可以对小麦籽粒图像中的多层次特征进行快速有效的提取, 因此在小麦不

完善粒检测的任务中得以应用,为实现农业的智能化提供了新的动力。Sa^[34]为了协助农业机器人对甜椒进行有效识别并采取抓取动作,在数据集方面使用迁移学习对甜椒近红外识别下的特征进行复用,加快了训练进程。并且 Sa 在 Faster R-CNN 模型的基础上提出 Faster Region-based CNN 快速检测网络,该文所改进模型相比于为改进前 F1 分数由 0.807 提升为 0.838。曹婷翠^[35]分析不完善粒的检测任务需要提高模型对小麦籽粒表面复杂特征的提取能力。作者首先建立符合需求的数据库(Wheat Image),并通过引入噪声的方式增加小麦的复杂特征。区别于传统的卷积神经网络,提出基于特征融合和池化理论优化的检测网络,实验表明数据库的建立以及网络模型的改进使不完善粒的检测正确率达到 90%以上。张思雨^[36]为了完成对花生不完善粒的检测工作,首先提出基于高斯分布的学习率自适应更新方法,又通过引入迁移学习将花生的特征信息输入网络的特征层。实验表明,两项工作使花生不完善粒的检测准确率提高到 99.7%。学者 Rong^[37]为了满足核桃果实杂质快速检测的需求,分析了杂质在不同姿态下形状和颜色的特征,提出了基于多尺度残差的卷积神经网络,克服了传送带磨损缺口对检测的干扰。经过验证集训练的结果表明,对于图像中异物的检测准确率达到了 96.5%,完成单张图像检测的时间低于 60ms。学者 Zhang^[38]将注意力机制引入到不同深度的网络结构中,观察不同位置的注意力机制对识别准确率的影响能力,实验表明在网络深度为 50 层的 ResNet-50 平均识别率达到了 97.5%。该文中不同深度引入注意力机制对检测能力对比的实验,表明了注意力机制在不完善粒检测的任务中,是具有参数小、高特征提取性能模块。宋怀波^[39]提出了基于改进 YOLOV5-S 的小麦籽粒检测模型,通过对基础网络的主干网络、激活函数、特征提取网络进行优化,在加快模型检测的基础上保持了高准确率。实验表明,改进后 YOLO V5-MDC 的检测准确率为 98.60%,检测时间缩短至 0.08s,实现了粘连小麦籽粒的有效检测。学者 Zhang^[40]为了对小麦枯萎病进行有效检测,对 YOLOV5 的模型结构进行优化,使其以 HSV 和 CMYK 为基准提取图像中的综合颜色特征,对于病害部位检测框偏移的问题使用基于非极大值抑制的 DIOU-NMS 方法优化。实验结果显示,经优化后网络的检测准确率提升到 96.16%。学者吴兰^[41]通过对 YOLOX 网络的特征融合层进行改进,使用提取能力更强的加权双向特征金字塔结构,并使用坐标注意力机制有效解决不完善粒检测过程中检测台环境干扰检测的问题。实验结果表明,对不完善的检测平均精度达到 93.43%,漏检率低于 5%。马洪娟^[42]通过对红外慢反射光谱和深度学习两种方式结合对小麦不完善粒进行检测,使用

SAE 对不完善粒近红外光谱进行检测, 实验表明深度学习方法对两种不完善类别的检测准确率为 92.52%和 90.52%, 高于线性判别方法。学者 Qiu^[43]通过提出基于 YOLO-SDL 的小麦籽粒质量检测方法, 该网络在主干提取网络部分采用 ShuffleNetV2 结构, 在轻量化的基础上采用 LSKA 注意力机制的高提取能力。实验表明, 在具有快速检测能力的基础上该模型检测准确率达到了 94.2%。在小麦不完善粒检测领域, 国内外学者使用深度学习方法满足了不同谷物外观品质的检测, 但大部分采用对单粒小麦分割操作简化识别方式, 并且部分检测任务中将小麦位置摆放整齐后进行检测, 降低了检测效率。

1.2.2 储麦品质预测的国内外研究现状

对于储麦质量评估任务, 国内外有许多学者对其进行研究, 除上述基于视觉的方法, 还有基于声波反射信号与基于储麦气体含量两个方面进行检测。从基于声波反射的方法进行分析, 方建军^[44]通过对粮食水分与声学频率特性之间的相关性分析, 得出当频率在 10-20KHz 范围内, 粮食水分含量与频率呈统计线性关系。基于此规律分析, 研制了粮食水分测量装置。学者 García-Álvarez^[45]使用超声波技术, 对小麦面团中的蛋白质和淀粉糊化情况进行检测。实验通过对 35 个由不同物理性质构成面团进行检测, 结果表明超声波可以作为面粉团中蛋白酶含量测定的无损检测方法。Marzec^[46]为了区分小麦籽粒的种类, 对小麦的机械特性和声学特性进行分析, 发现两种规律结合与小麦蛋白质含量显著相关, 基于此规律完成了对小麦籽粒品种区分的工作, 但实验中其机械特性的发现可能会损坏小麦结构。李广超^[47]为了对小麦水分含量进行测定, 首先研制了小麦声波反射信号接收装置, 对接收到的声学信号从模拟信号转换为计算机可处理的数字信号, 对处理后信号的时域频域进行分析, 提取小麦水分含量的声学特征输入到神经网络中进行检测, 其测量的平均误差为-0.0692%, 证明声学可作为小麦品质测定的手段。杨梅^[48]通过对小麦籽粒撞击金属板的声波进行分析, 发现健康籽粒与霉变籽粒由于外观状态差异较大导致两者撞击发出的声学信号存在差异。基于此规律在小麦碰撞声波信号中引入分类因子和核函数, 实验表明引入分类因子实现了小麦霉变的高效检测。学者 Salimi Khorshidi^[49]为了对加拿大五种小麦品种进行区分和质量评估, 使用 0.5-10 兆赫兹范围内的五个声波进行实验, 并结合主成分分析和广义线性模型作为评估方法, 实验发现 10MHz 信号测量得到的参数与小麦种类更具有相关性, 与其他

频率相比 10MHz 为最佳判别频率,但本实验中所使用的设备成本偏高,不适应大规模的检测。学者 Guo^[50]通过对冲击声学信号的研究并与统计学方法结合,提出了基于高斯建模和信号处理的小麦发芽粒和虫蚀粒检测方法。声学信号通过高斯建模方法对不完善粒的判别特征进行有效提取并进行检测,实验表明此方法对健康粒的检测准确率为 92%,对虫害颗粒的检测率为 96%,发芽颗粒的检测率达到了 95%。基于声学检测的研究中,声学信号的发出往往基于小麦籽粒对金属板的碰撞,由于撞击力度较小,因此基于声学检测可实现对小麦品质的无损检测方法。但声学信号在采集时往往受到环境噪声的干扰。

由于储麦自身的呼吸作用产生二氧化碳,因此气体的含量也作为监测储麦品质变化的指标^[51]。惠国华^[52]为了解决谷物霉变发现滞后的问题,开发了基于气敏传感器的检测装置,采用非线性双稳态随机共振系统检测并提取霉变气体的特征,此装置可检测大米、黑芝麻、燕麦等谷物的健康情况,但本实验中检测设备的搭建成本颇高。学者 Huo^[53]根据人工品鉴绿茶的方式开发电子舌和电子鼻传感器,对绿茶液体的味道和气味进行检测,并通过主成分分析和聚类分析将挥发出的化学成分进行鉴定,以此区分绿茶等级与产地。实验表明相比人工方法,两种传感器的开发提高了品鉴效率。学者 Barkat^[54]通过测量小麦挥发性化合物 VOC 气体的产生,对澳洲地区收获小麦是否存在真菌进行检测。该实验中使用气相色谱-质谱联用法检测小麦籽粒中的真菌,在本实验中虽然可以利用 VOC 气体检测,但检测步骤繁琐导致效率低下。林振华^[55]在其检测小麦霉变的实验中,使用 8 个传感器构成电子鼻系统。使用主成分分析法对冗余传感器进行优化,并将检测结果作为 BP 神经网络的输入,实验表明 BP 网络模型的预测值与测量值的相关性达到 0.91,但本实验中 BP 神经网络只能对霉菌含量进行短期预测。学者 Wadood^[56]为了分析小麦品种的品质等级和地理产区,使用小麦挥发性物质芳香族特征,构建线性判别模型。采用顶空固相微萃取-气相色谱-质谱联用方法对 32 个地区的小麦品种进行检测,结果显示不同等级和不同品种之间检测结果具有很大差异。通过开发气敏传感器对小麦挥发性气体的检测虽然可以做到无损检测,但是在小麦气体产生过程中气体浓度易受环境因素的干扰,并且储麦中的气体不仅由小麦自身呼吸产生,微生物的化学反应也会产生相同成分的气体,其复杂的来源也是干扰检测因素之一。

因此也有学者使用深度学习的方式对储麦品质进行预测,蒋华伟^[57]以反向传播网络为基础,采用改进的 PSO 粒子群智能算法优化模型寻优阶段,构建 IPSO-BPNN 模

型,并对改进前后模型的预测效果进行对比。实验证明,模型的改进措施降低了均方根误差。学者 Sandhu^[58]为了评估深度学习预测小麦品质的能力,使用卷积神经网络 CNN 和多层感知机对春小麦品质进行检测,实验过程中对深度学习方法进行超参数优化,结果表明深度学习在小麦五种性状的预测精度均高于多层感知机。学者 Chen^[59]通过分析发现储粮温度的波动与害虫活动频繁与否密切相关,因此对储藏过程中小麦的温度进行预测。通过使用 Adaboost、决策树、额外树和随机森林 4 种不同的机器学习模型进行微调,增强模型的预测能力,并将四种模型集成为融合模型。结果表明,融合模型可以实现更高精度的温度预测。上述使用深度学习方法对小麦的相关指标进行预测,经过对深度学习方法的改进使其在各个任务中完成高精度的预测,但是目前对小麦品质预测还停留在人工设定参数阶段,模型的适用性和泛化能力遭到限制,影响模型拟合阶段最优解的推理。

1.3 本文研究内容

现有算法虽然可对紧贴状态的小麦籽粒进行有效检测,但是检测模式均为光照条件良好的检测台进行离线检测,被检测小麦为粮堆中取样得到,检测范围仅局限在取样点附近。无法满足对小麦不完善粒的在线检测。并且,在小麦生理生化指标预测任务中,因样本稀缺而导致预测效果不理想。

针对上述问题,本文为完成对粮堆表面不完善粒的在线检测和小麦生理指标的有效预测两项工作,以仓储小麦为研究对象,以一阶段检测模型为基础构建粮堆表面不完善粒的在线检测模型。通过提取小麦生理生化指标原始数据特征对原始数据进行有效扩容,并通过预测网络的优化达到对指标的准确预测。应对了当前对小麦品质检测和预测方法的不足。本文的研究内容由三部分组成,研究内容框架如图 1-1 所示。

(1) 本文围绕粮堆表面小麦不完善颗粒在线检测的技术难题,针对单阶段检测模型在复杂粮堆表面图像中存在的漏检率高、实时性差等问题开展研究。通过分析传统卷积操作,在保证精度不降低的前提下,完成模型的轻量化。结合粮堆表面不完善粒的具体需要,提高模型对不完善颗粒关键特征的提取能力,以应对复杂背景对不完善颗粒检测的干扰。构建高分辨率特征图与深层语义特征的有效机制,提升模型对细微纹理特征的识别能力。最终结合上述内容,搭建轻量化检测模型并进行有效检测。

(2) 针对小麦生理生化指标预测任务中样本稀缺与生成对抗网络生成数据质量低

下的双重问题。本文建立基于特征提取的生成对抗网络，对原始数据特征向量与可控噪声向量进行非线性耦合，优化传统 GAN 网络因随机噪声导致生成数据特征偏移的问题，实现原始数据在关键特征分布方向上的定向扩展。在生成数据评判阶段，构建双通道损失函数，建立具有指向性的判别机制，优先保留与原始数据特征分布具有相似性的数据。保证在特征分布相似的情况下，实现储麦生理生化指标数据的扩容。

(3) 对于储麦生理生化指标因受到多环境因素耦合而干扰模型预测效果的问题。本文提出融合迁移学习与智能化算法的模型改进方法。设计源域-目标域动态知识嫁接机制，构建包含储麦生理生化指标变化趋势的复用特征源域数据库，使用增容数据在预训练阶段提取储麦指标公共特征。建立动态平衡的混合优化策略，通过引入柯西变异扰动增强模型初期全局搜索能力，后期使用高斯分布对局部搜索做精细化调节，增强模型寻优能力，完成多因素耦合影响下的储麦生理生化指标预测任务。




图 1-1 本文研究内容框架

1.4 本文组织结构

本文内容共分为六个章节，框架如图 1-2 所示。章节详细内容如下所示：

第一章 绪论。本章对储麦不完善粒检测与生理生化指标预测的研究背景及其意义进行介绍，并分析国内外研究现状的不足。章节末尾对本文研究内容与章节安排进行详细阐述。

第二章 相关技术及理论分析。本章首先对储麦不完善粒在线检测相关技术及理论进行分析，对于储麦不完善粒检测的研究，介绍深度学习以及一阶段与二阶段检测算法的不同，并分析粮仓内部不完善粒检测的需求。对储麦生理生化指标预测相关技术及理论进行分析，对于储麦生理生化指标检测的研究，分析粮仓内部环境的耦合对储麦生理生化指标的影响。并对传统的预测网络进行介绍，分析网络模型在预测中的不足与缺陷。

第三章 基于轻量化模型的粮堆表面不完善粒检测方法。本章首先结合上述章节中粮堆表面不完善粒的具体需求，分析神经网络的特征提取方式，结合 SENet 注意力机制，通过对特征提取方式的改进与关键特征权重的放大，优化不完善粒特征的提取方式。通过引入小目标检测层提升高语义信息利用率，构建增强特征金字塔网络(Increase-FPN)。上述改进措施使 IDS-YOLO 在保持高特征提取效果的同时将模型参数量压缩至 5.5M。最后，将 IDS-YOLO 网络与其他对比算法在漏检率、模型鲁棒性、模型综合性能方面进行了比较，证明了 IDS-YOLO 满足粮堆表面不完善粒的检测需求。

第四章 基于 Feature-GAN 的储麦品质数据扩容方法。本章通过构建生理生化指标数据特征提取器，将原始数据的特征向量与随机噪声进行拼接，指向性的生成新样本，优化 GAN 网络生成数据范围单一的问题。在判别机制中使用对抗损失与特征匹配损失构成联合损失判别函数，确保生成数据与原始特征分布的一致性。实验表明，优化后 Feature-GAN 网络生成数据和 GAN 网络生成数据与原始数据的相关性进行对比，证明优化方法可以有效扩充样本。

第五章 基于迁移学习和改进淘金热算法优化 LSTM 的储麦指标预测方法。本章通过对迁移学习策略的应用与 LSTM 结合构成 TL-LSTM 网络，该网络使模型在训练时可获取储麦生理生化指标变化趋势的共性特征，并有效缩小预测误差。使用柯西高斯混合分布扰动，并结合自适应调整策略，对模型寻优全过程进行优化，突破传统神经网络

络对先验知识的依赖瓶颈。实验证明，所提出的 TL-CGGRO-LSTM 优化算法，实现了对储麦生理生化指标变化趋势的精准预测。

第六章 总结与展望。本章对上述储麦品质检测与预测的工作进行总体总结，并基于本文所做工作，对未来储粮品质动态监测工作提出可能深入的研究方向。




图 1-2 本文组织框架结构图

1.5 本文数学符号阐述

根据上述研究现状分析以及本文研究内容和组织架构，本文应用深度学习方法对储麦品质进行检测，实验分析过程中所用数学符号较多，对基础数学符号在此节进行阐述：

$t-1$	描述上一时刻
t	描述当前时刻
$t+1$	描述下一时刻

W_i	代表权重矩阵
b	代表计算过程中的偏置
C	代表特征图个数
W	代表特征图宽度
H	代表特征图高度
K	代表单个卷积和大小
x_n	全局特征信息
F_{sq}	代表挤压操作
F_{ex}	代表激活操作
$\tan$	激活函数
$U_c(i, j)$	表示特征图信息
Par_3	逐点卷积的参数量
Par_{all}	深度分离卷积参数总量
$G(Loss)$	表示生成器损失函数
$D(Loss)$	表示判别器损失函数
P_r	真实数据分布
P_z	生成器随机噪声
z_i	输入生成器随机噪声
x_i	输入的真实数据
$x(i_1, j_1, t_1)$	表示小麦理化指标数据矩阵
$E(X, \delta)$	表示降维提取特征过程
Y	表示生成数据
θ	生成器相关参数
z_{con}	特征拼接后的噪声

λ_k	第 k 个特征值
α_k	特征向量
β	判别器权重系数
O_t	表示输出门信息
f_t	表示遗忘门信息
i_t	表示输入门信息
U_f 、 W_f	遗忘门状态参数
h_{t-1}	上一时刻隐藏层输入
μ	表示激活函数
U_i 、 W_i	输入门状态参数
C_t 、 C_{t-1}	记忆单元内部状态
$\tilde{C}_t$	当前时刻更新状态
U_o 、 W_o	输出门的参数
X_i	淘金者位置
$\vec{X}^*(t)$	最佳金矿位置
$\vec{D}_1$	淘金者于金矿位置
$\vec{A}_1$	淘金者移动方向
$\vec{C}_1$	淘金者步长因子
$\vec{X}_{new,t}(t+1)$	淘金者最新更新位置
$\vec{r}_1$	移动方向随机因子
λ	表示自适应调整系数
T	代表总迭代次数

w_{max}	初始阶段柯西分布系数
w_{min}	柯西分布权重下限
RMSE	表示均方根误差
MAE	平均绝对误差
R^2	决定系数

2 相关技术与理论分析

对于不完善粒检测的研究，本章首先对基础的神经网络模型进行解析，并重点对比一阶段算法与二阶段算法的不同之处，围绕小目标检测的理论进行分析。对于储麦生理生化指标预测的研究，本章首先对储麦生理生化指标的变化趋势进行理论分析，阐明数据增强的概念及方法，并对处理长时序数据的方法进行介绍。

2.1 目标检测相关技术

2.1.1 卷积神经网络

卷积神经网络(Convolutional Neural Network, CNN)，最初应用于手写字符的识别任务。其主要特点为识别并处理网格状态的数据结构，在图像、视频、语音信号的处理任务中应用广泛。为了提升图像分类的准确性，卷积神经网络不断从图像中提取局部特征，并通过共享权重的方式优化其参数。如图 2-1 所示，卷积神经网络的结构由几个核心部分组成：输入层、卷积层、激活函数、池化层、全连接层和输出层。在模型优化参数的过程中，卷积层提取图像中的有用特征，池化层的操作可避免模型过拟合，全连接层构成全局特征实现对目标图像的分类。




图 2-1 卷积神经网络结构图

2.1.2 目标检测算法

在目标检测领域，通过检测方法将算法分为了两大类别。一阶段检测算法包含应用广泛的为 SSD（Single Shot MultiBox Detector）和 YOLO（You Only Look Once）系列。二阶段检测算法，包括 RCNN（Regions with CNN features）、Fast R-CNN 和 Faster R-CNN。一阶段算法的核心思想在于，模型仅需一次计算推理，便可直接生成目标的预测框及其对应的类别概率。因此，一阶段的模型框架为端到端，不仅检测流程得到简化，模型计算推理的速度也得到提升。二阶段算法检测任务分为先定位、后分类。定位是指模型在推理中生成相应的候选区域，在确定候选区域的基础上，在其内部进行精准分类。一阶段与二阶段算法的常规流程对比如图 2-2 所示。由图可知，一阶段由于在推理过程中，省略了候选区域生成和相应的 ROI 细化步骤，直接输出检测结果，因此一阶段模型的计算量显著降低并且还有低内存占用率、高检测速度的优点。

经典的一阶段算法主要为 SSD、YOLO 系列，以下将对一阶段算法进行详细介绍，包括它们的原理、结构、优势。




图 2-2 一阶段算法与二阶段算法检测流程对比

2.1.3 SSD 检测算法

SSD (Single Shot MultiBox Detector, SSD), 其结构图如图 2-3 所示。SSD 作为单阶段检测算法, 有着不俗的检测速度。该算法设计亮点为采用多尺度特征, 对不同层级的特征图进行应用, 从而对不同尺寸的目标进行检测。




图 2-3 SSD 网络结构图

根据 SSD 的结构图所示, 其主干提取网络由 VGG16 网络组成, 从主干网络采样后生成不同尺度的特征图, 再经过 3×3 的卷积步骤执行相应的分类回归任务。其中, 高分辨率的特征图 (38×38) 蕴含着更多的原始图像信息, 对小目标的检测提供特征细节。位于结构图的最右层, 尺度为 1×1 的特征图则可以完成对大目标的检测任务。但是 SSD 仅对导出的特征图进行单层应用, 并未将特征图的信息进行融合处理, 这也导致了 SSD 算法在高层特征图的语义信息不足, 影响最终的检测结果。

2.1.4 YOLOV3 检测算法

YOLOV3 的结构图如图 2-4 所示。相较于 SSD 模型, YOLOV3 的主干网络采用了 Darknet-53 架构。通过融入残差连接的设计, Darknet-53 有效改善了深度神经网络中梯度消失的问题。这种网络结构使模型在输入图像特征提取阶段展现出更强的表征能力。

在特征提取方面与 SSD 相比, YOLOV3 同样对多个特征图进行了应用, 如结构图所示, 分别使用尺度为 13×13 、 26×26 、 52×52 的三组特征图。其中, 13×13 的特征图保留了原始图像中显著的特征, 因此用于检测较大的目标; 26×26 的特征图相比于 13×13 的特征图保留了一定的原始信息, 针对小尺寸目标的检测需求, 52×52 特征层通过保留多原始图像信息, 有效提高了模型对小尺寸目标的检测精度, 从而提升网络对图像中小目标特征的提取能力。

在损失函数的应用方面, YOLOV3 的损失函数有三部分。在模型的训练过程中, 目标置信度损失 (Objectness Loss) 提高模型对边界框内目标的预测能力, 对于检测目标位置的确定, 则由边界框损失函数 (Bounding Box Loss) 进行优化, 采用类别损失函数以达到对检测物体类别更好的判定。在训练阶段, YOLOV3 通过三种损失函数的联

合优化，不断更新模型的权重，最终达到对目标物体的检测。




图 2-4 YOLOV3 网络模型结构图

2.1.5 YOLOV4-Tiny 检测算法

YOLOv4-Tiny 的总体结构主要分为三个部分：第一部分是用于加速图像特征提取的 CSPDarknet 53-tiny，该部分由三个 BasicConv-blocks 和三个 Resblock-body 所组成，并且在 BasicConv-blocks 中，YOLOV4 中的 Mish 函数被替换为了 Leaky-ReLu 激活函数，其主要原因是为了提升提取特征的速度。

而在 Resblock-body 中使用了 CSPnt 结构，一部分如残差边缘一样，保留相关信息用于最终融合处理，另一部分继续堆叠原始残差块，为了能够更好地捕捉图像的语义信息，残差连接的路径也包括多个卷积层和归一化层。第二部分是 FPN，其主要作用是进行多尺度特征融合，这部分相比于其他的网络模型只有一个上采样层，第三部分为 YOLO Head 输出层，输出的尺寸为(19, 19, 75) 和(38, 38, 75)。其结构如图 2-5 所示。相比于其他一阶段检测算法，YOLOv4-Tiny 的结构简洁使其有高实时性的优势。




图 2-5 YOLOV4-Tiny 网络结构图

2.2 粮堆表面不完善粒检测任务需求分析

表 2-1 为各个目标检测算法使用公开数据集进行训练得出的模型参数，根据上述对一阶段和二阶段检测算法的对比分析发现，二阶段算法先使用定义候选区域再进行精细化识别处理，因此二阶段检测算法对于目标检测的精度更高，但由于其模型的参数量大、计算推理复杂的问题导致二阶段检测模型实时性差，FPS（Frames Per Second，FPS）值介于 5~10 之间，使其适合于医学图像处理等静态检测场景。对于一阶段检测算法而言，虽然检测速度较快，但本文检测算法部署的平台为小型粮食无人机，小型设备由于其硬件资源受限，因此在粮堆表面不完善粒的检测任务中，适合轻量化模型的部署以满足实时性的需求。

表 2-1 不同检测算法参数对比

模型	SSD	YOLOV3	YOLOV4	Faster R-CNN	YOLOV4-Tiny
参数大小/M	26	62	64	137	6
FPS	20~30	30~40	30~40	5~10	200~300

2.3 基于轻量化模型的粮堆表面不完善粒检测过程

基于上述分析，本文建立粮堆表面不完善粒在线检测模型的步骤如下：

- （1）制作粮堆表面不完善粒数据集：通过粮食无人机对图像采集，对虫蚀粒与破

- 损粒的特征进行标注，并对数据集进行扩充，满足模型训练所需的数量，避免过拟合。
- （2）检测模型选择：对比主流轻量化模型，从模型参数、检测速度、模型性能进行对比，选取合适的轻量化模型作为基础模型。
- （3）模型改进：本文的任务需要弥补轻量化模型因其参数量小而产生特征提取能力较弱的问题，本文需要提升轻量化模型对不完善粒特征的识别能力，帮助模型在检测时兼顾检测速度与精度。
- （4）模型改进评估：通过消融实验，对比模型改进前后的性能。并且对比本文提出模型与主流轻量化模型不完善粒的检测能力。
- （5）模型的应用与验证：使用训练好的模型对不同场景的不完善粒进行检测，分析对比改进模型检测能力，评估改进模型在实际应用中的表现能力。

2.4 储麦生理生化指标预测相关技术

2.4.1 循环神经网络




图 2-6 RNN 循环网络模型结构

与基础的反向神经网络不同，根据结构图可以看出，由于其有着循环结构，因此可以不断的处理当前信息并在当前时间将信息传播至隐藏层，形成 RNN 网络的隐藏态，形成过程如公式(2-1)所示：

$$h_t = f(W_{hh} \cdot h_{t-1} + W_{xh} \cdot x_t + b)$$

(2-1)

式子的含义为，当前时刻的隐状态 h_t 由上一时刻的隐状态 h_{t-1} 、当前时刻的输入信息 x_t ，与权重矩阵 W_{hh} 、 W_{xh} 和偏置项 b 进行计算得出。RNN 网络输出信息的表达式如 (2-2)所示：

$$y_t = W_{hy} \cdot h_t + b_y$$

(2-2)

根据表达含义，RNN 当前时刻的输出信息由当前时刻的隐藏层信息 h_t 、输出层权

重 W_{hy} 与输出层偏置 b_y 得出, 因此 RNN 可以有效的处理时序数据。在时间跨度较长的时序处理任务中, RNN 由于权值的设置和运算方式会不断的做累乘运算, 因此会产生梯度爆炸的问题。对于此项问题, 相当多的学者提出了解决方法。例如通过权重正则化, 对权重值的范围进行限制, 优化累乘运算中权重值过大影响推理的问题。也会通过对梯度值进行修正, 例如梯度裁剪和梯度剪枝方法, 这些方法的核心在于将梯度值按比例缩放或断开梯度链将梯度限定在某一范围, 以确保模型的正常推理运算。

2.4.2 数据增强

深度学习模型在其应用领域显著提高了工作效率, 但在特定场景下深度学习由于数据集缺失的问题而导致应用受限。在特定场景中, 由于受到隐私保护和获取成本高等问题, 构建高质量的训练数据集是特定场景下深度学习应用的普遍挑战。由此, 兴起了小样本学习的方法, 该类方法通常加强学习数据的隐藏特征以提高模型的预测效果, 但数据量稀少造成特征不足的问题依然存在。

数据增强通过对原始数据进行有监督方式变换进而完成训练样本的扩充, 其变换的方式包括色度调整、添加噪声点、旋转缩放等, 原始训练数据经过变换后增加了更多复杂特征, 使模型在训练时通过学习到更多特征降低过拟合的概率。在预测任务中, 大规模高质量包含复杂特征的数据, 可使模型的泛化能力得到提升。因此, 数据增强是解决储麦品质检测和预测任务中样本量稀缺的有效手段。

2.4.3 迁移学习

迁移学习 (Transfer Learning) 是一种机器学习方法, 其核心思想是通过对源域数据知识的学习结果嫁接至目标域的训练任务中, 提高目标域模型的学习能力和泛化能力。迁移学习的结构如图 2-7 所示, 其中源域为提供公用特征的知识库, 目标域为需要知识经验的相关领域, 并且源域任务和目标域任务具有一定的相关性。在源域任务完成的基础上, 通过基于实例、特征、模型、任务四种迁移方式将相关知识应用于目标域, 四种迁移方式的区分如表 2-2 所示。在不同目标域任务中, 可以使用更为方便的方式完成源域知识的运用。

在储麦生理生化指标预测的任务中, 为了满足模型可以预测不同储藏情况下

指标变化的趋势，迁移学习可对公共特征复用的特性将被应用于预测任务中。




图 2-7 迁移学习方法框架

表 2-2 迁移学习方法的类型

迁移学习方法	方法描述
基于实例的迁移学习	在源域和目标域相似的场景中，将源域数据移动至目标域数据中
基于特征的迁移学习	源域与目标特征空间相似的情况下，目标域使用源域的数据特征对任务进优化
基于模型的迁移学习	通过对源域模型参数的优化并迁移至目标域任务
基于关系的迁移学习	将源域目标域的任务实例特征映射至新的数据空间

2.5 储麦生理生化指标变化趋势分析

小麦在仓储过程中，脱壳小麦与储藏环境的直接接触使小麦的品质不再由其自身特性所决定。小麦籽粒与储藏环境中的各个要素进行相互影响，使小麦内部的变化更加复杂，这种复杂情况由粮仓内部多变的温度场、湿度场、微生物场耦合作用所展现。例如，小麦籽粒本身的水分，不仅受到粮仓中湿度的影响，也会受到自身呼吸作用的影响。而粮堆小麦由于自身呼吸作用形成了由高到低的温度差，温度的不同也会影响各个生理生化指标值。本文选取了可以反应小麦品质好坏的生理生化指标，表 2-3 中列举了国家标准指定的理化指标及其测试方法。如表 2-3 所示，小麦品质的好坏与各个生理生化指标变化息息相关，可以通过各种理化指标结合对小麦品质做出有效评估，以此作为反馈机制，及时对储藏策略进行调整。

除了表中的品质评价指标，过氧化物酶、吸水率以及发芽率等理化指标均可以对小麦品质进行评估。例如，发芽率可以评价小麦籽粒活性与生命力等品质，过氧化物酶的酶活性会随着小麦细胞结构损伤而降低，可作为评估小麦籽粒细胞结构是否完好的重要指标。

表 2-3 储麦生理生化指标阐述

指标	测试方法	品质评价原理
蛋白质	GB/T 21119-2007	蛋白质的降解与储存条件密切相关。在高温、高湿条件下，蛋白质水解程度显著高于低温、低湿储存条件。并且蛋白质含量的降低可能表明小麦籽粒受到微生物的侵蚀或酶的降解，导致品质下降。
水分	GB 5009.3-2016	水分含量是影响小麦籽粒储存稳定性的重要因素。高水分含量会促进微生物的生长和繁殖，导致小麦籽粒发霉、变质。通过测定水分含量，可以确定小麦籽粒是否适合当前的储存条件。
脂肪酸值	GB/T 15684-95	脂肪酸值是评估小麦籽粒储存品质的重要指标之一。在储存过程中，脂肪酸值的升高表明小麦籽粒中的脂肪酸氧化程度增加，品质下降。通过测定脂肪酸值，可以及时发现小麦籽粒的品质变化，采取相应的措施进行处理
电导率	电导率=（浸出液电导率-初始电导率）/种子重量	电解质渗出程度受细胞膜重建和损失修复能力影响，种子活力高，能对膜进行快速修复重建，电导率较低；种子活力差，则修复能力较弱，电导率较高。
峰值黏度	GB/T 24853-2010	峰值黏度与小麦制品的口感饱和度呈现正相关，峰值黏度值越高，口感与感官评分越高。

2.6 储麦生理生化指标预测过程

粮仓的管理调节是维持储粮品质的重要手段，对于储粮品质传统的监测方法主要由基于声学、基于光学以及使用气体含量进行检测。但基于声学的检测方法虽然对储麦状态没有损害，但处于堆叠状态的粮食会对声波产生较高的干扰。基于光学可以对粮食外观进行检测，但外观问题的发现也代表储粮指标已经异常。使用气体进行检测，气体含量则受到的其挥发性的影响导致其在检测领域的不稳定性。而基于深度学习的储粮品质无损预测，虽能通过对数据的特征提取实现快速精准评估，但其性能高度依赖高质量的储麦生理生化指标数据集。基于上述对深度学习、数据增强、迁移学习方法的分析，本文采用基于数据增强联合迁移学习的样本扩容方法，在此基础上应用深度学习的方法进行储麦生理生化指标的有效预测，模型建立方法如下所示：

（1）储麦数据预处理：对收集到的储麦生理生化数据进行异常值剔除，保证数据的质量，并且筛选与储麦品质相关的指标作为预测目标。

（2）建立数据增强模型：分析基础数据增强方法，对数据增强模型进行改进，使其生成与原数据相似的高质量样本。

（3）预训练模型的嫁接：对储麦生理生化指标进行通用特征复用，并验证复用效果。

（4）预测模型的训练：在预训练模型使用的基础上对目标域数据进行训练，使用测试集对训练效果进行验证。

（5）预测效果评估：使用不同的目标域进行训练，观察预测趋势，对预测效果进行评估。

2.7 本章小结

粮堆表面不完善粒的检测因其场景在密闭的粮仓中，因此算法所搭载设备的硬件算力受到限制，本章首先阐述神经网络的各个结构组成部分，对目前检测算法的类型简要概括。通过结合粮堆表面不完善粒检测的实际需求，并对检测算法的检测参数进行对比，得出在此任务中需要轻量化检测算法的结论。本章末尾，明确了基于轻量化模型的不完善粒检测方法，轻量化模型的高速检测能力，即使在算力受限的情况下依旧可以保持较高的 FPS 值，在后续的优化过程中，需要在满足检测实时性的基础上提高

模型的检测精度以降低模型对不完善粒的漏检率。

本章围绕储麦不完善粒检测和生理生化指标预测任务的需求展开分析，对两种任务的不同方法进行阐述。对于不完善粒检测任务，本文分析了基于深度学习的检测方法，并通过对一阶段、二阶段、轻量化模型性能的对比选取了合适的检测模型。对于储麦生理生化指标预测任务，选取了处理长时序数据的基础模型，并分析明确了样本稀缺的关键问题，为后续检测、预测模型的搭建做好基础工作。

3 基于轻量化模型的粮堆表面不完善粒检测

3.1 引言

小麦颗粒完善与否是储粮品质优劣的重要指标之一，现阶段仓内粮堆表面的粮情检测可由智能设备协助完成。智能设备所采集的粮堆表面图片背景密集复杂、颗粒互相重叠对检测形成噪声干扰。对于粘连或遮挡状态下提升小目标的检测准确率，学者 Gao 等^[60]通过研究目标检测算法的优化模块，提出了一种基于 Res1-D-CBAM-Atrous 的小麦不健全内核检测方法，缩短了小麦不完善颗粒的检测时间，但精度相对于原有模型提升有限，仅仅提升 4%。学者李震等^[61]通过对 YOLOV7-Tiny 的改进，对模型进行轻量化处理，将改进后的算法内嵌入检测装置中，将改进前后算法均部署到检测平台中进行对比，YOLOV7 的检测时间为 12.5ms，经过轻量化处理后的模型检测时间减少到 10.1ms，但准确率相对原有模型仅提升 0.27%。学者 Gai 等^[62]通过改进 YOLOV4 目标检测算法，通过加深网络深度、修改先验框形状，适用于体积较小的樱桃，解决了樱桃果实重叠难以检测的问题。学者 Zhang 等^[63]通过改进 YOLOv5 目标检测模型，改进后的模型可以有效检测相邻紧贴的小麦赤霉孢子，并且检测速度得到了提升，但模型的准确率仅为 90.67%。学者 Zhang 等^[64]提出一种结合注意力机制和残差网络（Residual net, ResNet）的小麦籽粒不完全识别方法，提高了检测粘连情况下小麦不完善颗粒的准确率。学者 Zhang 等^[65]通过嵌套 ECA-Net 注意力机制模块从而提高了对小麦萌发孢子这类小目标的检测准确率。上述提到算法虽然对紧贴状态目标进行有效检测，但是检测模式均为光照条件良好的检测台进行离线检测，被检测小麦为粮堆中取样得到，检测范围仅局限在取样点附近。

根据粮仓内部小麦不完善颗粒检测的实际需求^[66]，由算法部署在不同的硬件平台以此进行在线检测，因此所提出算法需兼顾精确度与检测速度。粮食仓储的过程中造成粮食损耗的最主要因素为害虫啃食的虫蚀粒，而在粮库日常管理中由于出入库等机械作业的操作失误，造成了极易吸引害虫啃食的破损粒。因此本文对粮食仓储环节中粮堆表面的虫蚀粒和破损粒进行检测。

3.2 数据集制作及模型选择

3.2.1 实验所用数据集

粮仓环境下的小麦不完善颗粒训练和测试还没有标准的数据集。因此在本文中，数据中一部分采用中国国家标准分类（GB 1351-2023）的虫蚀粒、破损粒，虫蚀粒与破损粒的定义如所表 3-1 所示。另一部分则使用本实验团队自主研发的粮食无人机等第三方检测平台在河南工业大学的实验粮仓中拍摄的虫蚀粒与破损粒的图像并通过 LabelImg 进行标注，数据集拍摄情况如图 3-1 所示。

表 3-1 虫蚀粒与破损粒的定义

种类	外观特征	影响危害
虫蚀颗粒	表面多有虫蚀孔洞	加工制品异味，品质劣变
破损颗粒	呈现破碎、压扁的状态	易黏附霉菌，增加虫害风险




图 3-1 数据集提取示意图

在数据集的制作中，为了更好地训练模型以及更加容易地评估模型的预测效果，数据集图片中不完善颗粒从数量方面分为 10、15 粒和 20 粒，从不完善颗粒的状态分为密集类型和分散类型。总共采集了 1 000 张图片采集的数据集如图 3-2 所示，数据集中图片尺寸为 843×843。



图 3-2 数据集样本

通过数据增强的方式对数据集进行添加噪声、垂直翻转和水平翻转处理，原有的图片经过数据增强后扩大到 4700 张，不同状态的样本图片比例均衡。使用 LabelImg 工具对数据集进行标注，将虫蚀粒与破损粒的标签命名为 “Broken Kernel” 与 “Injured Kernel”，并以 PASCALVOC 数据集格式保存，以 XML 文件形式记录图像信息，包括对象类别的像素坐标值和矩形边界的像素坐标值，训练集和测试集比例为 7：3。

3.2.2 模型选择

目前，主流的轻量化检测网络有 YOLOV10-S、YOLOV8-S、SSD、YOLOV4-Tiny、YOLOV7-Tiny，通过不完善颗粒数据集进行实验，对各个轻量化模型的性能进行对比。实验结果如表 3-2 所示。

表 3-2 轻量化模型性能对比

模型	mAP/%	参数量/MB	FPS 值
YOLOV8-S	93.60	11.18	35.71
SSD	89.04	26.28	57.57
YOLOV7-Tiny	91.37	6.22	53.41
YOLOV10-S	91.91	7.26	47.29
YOLOV4-Tiny	89.75	6.01	76.73




图 3-3 YOLOV4-Tiny 的结构图

表中 mAP 为均值平均精度值 (mean Average Precision, mAP)，FPS 为帧率 (Frames Per Second, FPS)。YOLOV8-S 的 mAP 相对于 YOLOV4-Tiny 略高，但是模型参数量为 YOLOV4-Tiny 的两倍，并且 FPS 值仅有 35.71。YOLOV7-Tiny 与 YOLOV10-S 的 mAP 值分别达到了 91.37%和 91.91%，但是 FPS 值较低。SSD 的 mAP 值低于 YOLOV4-Tiny。相比于其他轻量化模型，YOLOV4-Tiny 优化潜能较大，更符合高速度、高精度、低参数的实时检测需求。综合分析后，本文选择参数量更低并且 mAP 值与 FPS 值较高的 YOLOV4-Tiny 模型。其网络模型结构如图 3-3 所示，该网络模型的参数只有 6.01

MB，显著减少了计算机显存的消耗。

3.3 改进 YOLOV4-Tiny 模型

3.3.1 整体改进思路

为了能够使 YOLOV4-Tiny 完成粮仓中小麦不完善颗粒的实时检测，本文对原有模型进行以下改进：

- （1）注意力机制的添加：通过对 SENet 注意力机制进行改进，相比于原有的注意力机制，进一步放大不完善颗粒特征的权重，增强模型的检测精度。
- （2）构建小目标特征融合网络：通过增加小目标检测层，使模型在预测时可以利用更高层特征图的语义信息，降低模型对不完善颗粒的漏检率。在主干部分的 Resblock-body 与加强特征提取层（Feature Pyramid Networks，FPN）之间以及 3 个上采样通道中加入改进的 SENet 模块，改进后的 IDS-YOLO 如图 3-4 所示。
- （3）模型轻量化：将 Resblock-body 中的常规卷积操作采用深度可分离的方法对模型进行优化，提高特征提取的能力以及降低模型的参数量和计算量，满足实时检测所需模型高检测速度。




图 3-4 IDS-YOLO 模型结构

3.3.2 注意力机制的优化

本文所识别的小目标样本为不完善的小麦颗粒，因此需要注意力机制对目标提取更多的有效特征。为了使用最适合检测不完善粒的注意力机制，分别对 SENet（Squeeze-and-Excitation Networks, SENet）、CBAM（Convolutional Block Attention Module, CBAM）、CA（Coordinate Attention, CA）三种注意力机制的性能进行比较，性能比较结果如表 3-3 所示。

CBAM 注意力机制 mAP 值虽略高于 SENet 和 CA，但 CBAM 模块的参数为 SENet 的 4 倍之多，CA 模块的参数水平中等，但 mAP 值较低，综上所述，选择参数更小、mAP 值较高的 SENet 注意力机制模块。

表 3-3 注意力机制性能对比

注意力机制	参数量	mAP/%
SENet	14 336	93.13
CBAM	57 442	93.79
CA	21 541	92.76

SENet 是一种关注模型通道的注意力机制，其结构如图 3-5 所示。首先进行 Squeeze 操作，目的是将感受野变得更广，采用全局平均池化操作方法将 $H \times W \times C$ 挤压到 $1 \times 1 \times C$ ，平均池化的操作如式(3-1)所示：

$$x_n = F_{sq}(U_c) = \frac{1}{W \times H} \sum_{i=1}^W \sum_{j=1}^H U_c(i, j) \tag{3-1}$$

式中： H 和 W 分别表示输入特征图的高度和宽度； x_n 为全局特征信息； F_{sq} 为挤压操作。网络架构通过两个全连接层实现非线性映射，其中首层采用 ReLU 函数进行特征激活，末层则通过 Sigmoid 函数生成通道注意力权重。这有利于获取小麦破损颗粒不同通道中的权重信息。全连接层的操作如式(3-2)所示：

$$F_{ex}(z, W) = \sigma[W_2 \delta(W_1, z)] \tag{3-2}$$

在激活操作中，原有的 ReLU 输入小于零时，输出恒为零。但在本文中密集颗粒的环境中需要更加注意不完善颗粒的特征，因此将更加平滑的 ELU 作为激活操作的激活函数，以此对不完善颗粒的特征权重进一步放大。ReLU 和 ELU 的函数公式如(3-3)、(3-4)所示。当输入的值小于 0 时，ELU 依然可以做出有效的计算。ReLU 和 ELU 的对比如图 3-6 所示。

$$ReLU = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases} \tag{3-3}$$

$$ELU = \begin{cases} x, & x \geq 0 \\ e^x - 1, & x < 0 \end{cases}$$

(3-4)




图 3-5 SENet 注意力机制




图 3-6 ReLU 和 ELU 的图像对比

SENet 经过改进之后，有助于提高算法在密集情况下识别结果的准确率，并且 SENet 的参数较小。表 3-4 中为激活过程使用不同激活函数对模型性能的影响。

表 3-4 不同激活函数对模型性能的影响

激活函数	mAP/%
ReLU	93.18
LeakyReLU	92.95
ELU	94.02

3.3.3 多特征提取模块的构建

由于本文识别的不完善颗粒为小目标，存在分辨率较低和特征信息较少的问题，从而导致不完善粒容易被忽略或误分类，因此需要更高层特征图的语义信息。而 YOLOV4-Tiny 原本的特征融合网络对高层特征网络的语义信息利用较少，对于大目标

的检测性能尚可，但较小的目标往往无法得到充分地识别和精确地定位。

本文所使用的小麦数据集提取环境为复杂密集的环境，并且这些复杂背景存在的大量噪声对原有模型的预测产生了极大的影响。因此，本文通过对原有特征融合网络结构的优化，增加对高层语义信息的利用，从而降低漏检率。因此，本文提出增加一个小目标检测层， 52×52 的特征图保留了更多原始图像的语义信息，能够对小麦不完善粒的小目标进行更为精确的检测。在此基础上，将原有特征网络中 13×13 特征图与 26×26 特征图堆叠而成的融合特征图通过上采样卷积操作与 52×52 进行第二层堆叠，得到具有更丰富小目标特征信息的特征层。




图 3-7 多特征提取模块结构一

在粮仓内部检测时，拍摄角度倾斜和光线较暗也会影响型的预测结果。本文在增加小目标检测层的基础上，提出了两种架构如图 3-7、图 3-8 所示。图 3-7 中注意力机制仅仅对特征融合模块的特征图进行了权重的放大，而图 3-8 在此基础上对上采样通道中内嵌注意力机制获得更多不完善粒特征，并将所获得多余特征堆叠到原有特征图，从而获取更多的小目标特征信息。




图 3-8 多特征提取模块结构二

3.3.4 模型轻量化改进

YOLOV4-Tiny 网络的主干特征提取网络采用标准卷积模块构建，其具体实现架构如图 3-9 所示。其中，卷积层的个数表示为 N ， C 与 K 分别表示应每个卷积层中存在卷积核的个数与单个卷积核大小的尺寸。因此普通卷积层的参数 Par_{conv} 如式(3-5)所示：

$$Par_{conv} = N \times C \times K \times K \tag{3-5}$$

深度可分离卷积采用了与传统标准卷积不同的运算结构，其核心思想是将空间维度与通道维度的特征提取分步进行。深度卷积过程如图 3-10 所示。首先将输入图像分为三个独立通道，随后采用各通道独立的二维卷积核对各个单通道执行卷积计算操作。卷积过后生成每个通道卷积计算后的特征图。其中 C 为 RGB 图片输入通道个数并且与分离卷积操作的层数相同， K 为单个卷积核的大小。参数量 Par_2 的计算如式(3-6)所示：

$$Par_2 = C \times K \times K \tag{3-6}$$

深度可分离卷积的第二阶段运算建立在空间特征提取基础上，其输出通道维度保持与输入层一致。在此基础上进行第二步逐点卷积，通过配置 N 个 1×1 卷积滤波器，实现跨通道信息重建，最终输出的特征图维度由滤波器数量 N 决定，逐点卷积过程图见图 3-11，其中 N 为逐点卷积 Filter 的个数，分离卷积提取的特征图个数表示为 C ，与逐点卷积 Filter 中卷积核的个数相同。




图 3-9 常规卷积操作




图 3-10 深度卷积




图 3-11 逐点卷积

Par_3 为逐点卷积的参数量，其表示方式如式(3-7)所示。深度可分离卷积的参数总量 Par_{all} 如式(3-8)所示。深度可分离卷积与普通卷积之间参数量的比值如式(3-9)所示：

$$Par_3 = C \times N \tag{3-7}$$

$$Par_{all} = C \times K^2 + C \times N \tag{3-8}$$

$$\frac{Par_{all}}{Par_{conv}} = \frac{1}{N} + \frac{1}{K^2} \tag{3-9}$$

本文将 Resblock-body 中常规卷积推理替换为深度可分离的卷积方式，相比原模型改进后参数减少了一百万左右，极大地降低了模型的参数量和计算量。

3.4 实验环境及模型评价指标

3.4.1 实验环境

本文依托于 Windows 10 PC 上安装的 Intel(R)-i7 处理器、3.60 GHz CPU、32 GB RAM 和 12 GB 内存的 NVIDIA GeForce GTX 2080。相关的硬件和软件环境见表 3-5。

表 3-5 实验环境参数

设备	配置
CPU	Intel(R) Core(TM) i7-9700K, CPU/3.60 GHz
GPU	Nvidia GeForce GTX 2080/12 GB
Pytorch Framework	Pychram 2021, Torch 1.71
Accelerated Environment	CUDA 11.1

为了在训练时使计算机不受显存不足的干扰，在训练时的 Batch-Size=8，训练周期为 100 轮，最大学习率设置为 0.001。

3.4.2 模型评价指标

本文中的模型评价指标为：模型训练中的 LOSS 值用于评估模型的收敛性能，mAP 用于评估模型的性能，真阳性和假阳性的计算准确率、召回率是衡量模型预测效果的重要指标。F1 分数作为分类模型的核心评价标准，其独特价值在于通过综合考量查准率与查全率这两个关键参数，实现对模型性能的平衡评估。准确率、召回率、F1 分数计算如式(3-10)、(3-11)、(3-12)所示：

$$Precision = \frac{X_{TP}}{X_{TP} + X_{FP}}$$

(3-10)

$$Recall = \frac{X_{TP}}{X_{TP} + X_{FN}}$$

(3-11)

$$F1-Score = \frac{2 * Precision * Recall}{(Precision + Recall)}$$

(3-12)

在模型性能评估中，真阳性（True Positive ， TP）含义为被正确识别的实际阳性样本数量，伪阳性（False Positive ， FP）指代实际阴性样本被误判为阳性的数量，而伪阴性（False negative, FN）则反映实际阳性样本被错误归类为阴性的情况。准确率被定

义为真阳性样本数与模型预测阳性样本总量的比值，表征模型判定阳性样本的可靠性；召回率则通过真阳性样本与实际阳性样本总量的比例，量化模型对阳性类别的覆盖能力。F1 分数（ $0 \leq F1 \leq 1$ ）作为分类效能的综合平衡指标，其数学表达式为查准率与查全率的调和平均数。该指标通过融合两类关键评估参数，实现对模型预测效力的优化组合，其数值提升直接对应模型性能的增强。

3.5 实验结果与模型评估

3.5.1 消融实验

为了说明本文提出的改进算法在性能上的提升，分别对 YOLOV4-Tiny、YOLOV4-Tiny-D、YOLOV4-Tiny-S、YOLOV4-Tiny-F、YOLOV4-Tiny-FD、IDS-YOLO 的训练结果以及各项评价指标进行对比，其中 I 为增强特征提取模块（Increase-FPN）的缩写，D 为重构主干网络的方法（Depthwise Separable Convolution）的缩写，S 为本文中嵌入特征提取模块中改进的注意力机制（SENet）的缩写。“Broken Kernel”标签实验结果如表 3-6 所示，“Injured Kernel”标签实验结果如表 3-7 所示。

表 3-6 消融实验中各个模型对 “Broken Kernel” 的检测结果对比

模型	平均精度/%	准确率/%	召回率/%	F1 分数
YOLOV4-Tiny	87.35	91.74	90.66	0.91
YOLOV4-Tiny-I	92.76	94.62	94.46	0.95
YOLOV4-Tiny-D	90.71	93.87	93.78	0.94
YOLOV4-Tiny-S	91.20	94.09	93.64	0.94
YOLOV4-Tiny-ID	94.18	95.60	95.44	0.96
YOLOV4-Tiny-IS	96.14	96.44	96.85	0.97
IDS-YOLO	95.92	97.12	96.90	0.97

其中 YOLO-Tiny-D 是在原模型的基础上只进行了轻量化；YOLOV4-Tiny-S 是在 YOLOV4-Tiny 原本基础上，在采样通道中嵌入了改进后的 SENet；YOLOV4-Tiny-I 是在原有模型的基础上添加了小目标检测层；YOLOV4-Tiny-FD 是在添加检测层的基础上对主干进行了轻量化；IDS-YOLO 则在 YOLOV4-Tiny-FD 基础上在采样通道中嵌入了改进的 SENet。

表 3-7 消融实验中各个模型对 “Injured Kernel”的检测结果对比

模型	平均精度/%	准确率/%	召回率/%	F1 分数
YOLOV4-Tiny	92.02	93.65	95.10	0.94
YOLOV4-Tiny-I	95.81	96.54	97.13	0.97
YOLOV4-Tiny-D	93.47	96.12	96.50	0.96
YOLOV4-Tiny-S	96.84	97.14	98.14	0.98
YOLOV4-Tiny-ID	97.04	97.21	97.80	0.98
YOLOV4-Tiny-IS	97.81	97.84	98.28	0.98
IDS-YOLO	98.67	98.59	99.14	0.99

经量化评估验证，本文所构建的 IDS-YOLO 框架在关键性能指标对比中表现出显著优势，并且在检测速度、精确度以及漏检率 3 个方面达到平衡。原本模型和改进后模型的损失值图像和 mAP 值图像如图 3-12、图 3-13 所示。通过消融实验对比分析，本文提出算法在检测精度、召回率等核心性能参数上均有提高。改进模型与 YOLOV4-Tiny-D 对比，在速度上略低于 YOLOV4-Tiny-D，但是检测的准确度优于 YOLOV4-Tiny-D；与 YOLOV4-Tiny-IS 相比，准确度与模型整体性能相近，但是本文提出算法在模型的检测速度上有明显的提升。与 YOLOV4-Tiny-S、YOLOV4-Tiny-I、YOLOV4-Tiny-ID 相比，本文所提出算法在各项指标均优于对比模型。对比结果如表 3-8 所示。




图 3-12 改进模型与原始模型的损失曲线对比




图 3-13 改进模型与原始模型的 mAP 值对比




图 3-14 消融实验中各个模型的热力图对比

为了能够更加直观地表示改进算法的有效性，本文使用 Grad-CAM 绘制模型对消融实验中定量改变的模型进行分析。热力图中红色区越亮表示网络模型越关注不完善

粒的特征。热力图的对比结果如图 3-14 所示，结果显示 IDS-YOLO 模型输出的热力图中对不完善颗粒特征的更加关注。

表 3-8 各个模型的参数、检测速度和 mAP 值对比

模型	参数量	检测时间/s	FPS 值	浮点运算数/G	mAP/%
YOLOV4-Tiny	6 056 606	0.013	76.34	6.945	89.69
YOLOV4-Tiny-I	6 483 741	0.019	52.35	8.867	94.29
YOLOV4-Tiny-D	5 035 614	0.010 3	97.09	3.804	92.09
YOLOV4-Tiny-S	6 099 614	0.018	54.64	6.946	94.02
YOLOV4-Tiny-ID	5 462 749	0.015	65.35	5.752	95.61
YOLOV4-Tiny-IS	6 530 845	0.019	51.54	8.869	96.98
IDS-YOLO	5 509 853	0.011	88.03	5.754	97.30

3.5.2 不同模型参数的比较

本文使用相同粮仓内部的小麦不完善颗粒数据集分别在 YOLOV10-S、以及 YOLOV8-S、SSD、Moblenet-YOLOV4、YOLOV7-Tiny 这些轻量化模型中训练。参数对比如表 3-9，本文所提出的 IDS-YOLO 模型参数量为 5.5MB 相比于其他轻量化算法参数更低，mAP 值相比于其他模型平均高 6.2%。其中 FPS 的值是评估模型实时性的重要指标。通常情况下，支持实时目标检测的模型需要达到至少 30 帧/s 的处理速度，才能保证实时性能。

表 3-9 本文改进模型与其他模型检测速度和 mAP 值对比

模型	检测时间/s	FPS 值	mPA/%	参数/MB
YOLOV8-S	0.028	35.71	93.60	11.18
YOLOV10-S	0.021	47.29	91.91	7.26
SSD	0.018	57.57	89.04	26.28
YOLOV7-Tiny	0.019	53.41	91.37	6.22
Mobilenet-YOLOV4	0.022	44.13	89.57	12.68
IDS-YOLO	0.011	88.03	97.30	5.51

由实验结果可知 IDS-YOLO 的 FPS 值为 88，大于标准值并且高于其他对比算法，可以用于实时检测。表 3-10 为本文提出算法与现有检测不完善粒算法的性能对比，IDS-

YOLO 相比于 WNet 内存多 2.31MB，但 WNet 检测呈分散状态的不完善粒并且精确度相比于 IDS-YOLO 低 3.77%。相比除 WNet 外的其他算法，IDS-YOLO 的内存均低于所对比算法，精确度均高于其他算法。

表 3-10 本文改进模型与文献中模型性能的对比

模型	精确度/%	参数/MB
Res24-D-CBAM-ATHOS	94.22	10.77
WNet	93.35	3.2
ResNET-152	94.83	6.5
YT-SFNet	83.80	11.9
IDS-YOLO	97.12	5.51

3.5.3 不同模型训练结果的比较

为了验证本文所提出检测算法的准确性，本文对 YOLO 系列算法以及 SSD 算法在自建数据集上的性能进行对比分析。由于本文对比的指标含有 FPS 值，因此二阶段的 Faster-Rcnn 系列算法不进行对比试验。

表 3-11 为 IDS-YOLO 在“Broken Kernel”标签下与其他先进算法性能对比的相关结果。实验结果表明，IDS-YOLO 与其他模型相比取得了最好的综合性能，在检测破损颗粒样本时的平均精度值相比于 YOLOV8-S 高 3.25%，准确率高了 4.47%。与 YOLOV10-S 相比，平均精度值高 7.41%，准确率高 5.17%。IDS-YOLO 的检测准确率为 97.12%、召回率为 96.90%、平均精度为 95.92%、F1 分数为 0.97，各项指标均高于其他的轻量化模型，检测能力和模型的综合性能更高，具有更好的检测性能。

表 3-11 本文改进模型与其他模型在检测“Broken Kernel”的性能对比

模型	平均精度/%	准确率/%	召回率/%	F1 分数
YOLOV8-S	92.67	92.65	94.18	0.93
YOLOV10-S	88.51	91.95	90.91	0.91
SSD	87.07	92.33	92.77	0.93
YOLOV7-Tiny	90.30	92.64	93.50	0.93
Mobilenet-YOLOV4	85.39	89.94	89.31	0.90
IDS-YOLO	95.92	97.12	96.90	0.97

表 3-12 为 IDS-YOLO 在 “Injured Kernel” 标签下与其他先进算法性能对比的相关结果。IDS-YOLO 检测准确率为 98.59%、召回率为 99.14%、平均精度为 98.67%、F1 分数为 0.99。相比于其他轻量化算法，平均精度值平均高 5.27%，并且其他指标均高于其他轻量化算法。与 YOLOV8-S 模型相比，准确率高了 4.08%，平均精度高了 4.15%，F1 分数提升了 0.04。相比于 YOLOV10-S，平均精度值高 3.36%，准确率高 3.5%，F1 分数提升了 0.04。

表 3-12 本文改进模型与其他模型在检测 “Injured Kernel” 的性能对比

模型	平均精度/%	准确率/%	召回率/%	F1 分数
YOLOV8-S	94.52	94.51	96.16	0.95
YOLOV10-S	95.31	95.09	95.80	0.95
SSD	91.00	94.16	94.60	0.94
YOLOV7-Tiny	92.44	94.02	94.85	0.94
Mobilenet-YOLOV4	93.74	93.98	95.08	0.95
IDS-YOLO	98.67	98.59	99.14	0.99




图 3-15 不同模型在 20 粒的验证集中的检测结果对比

表 3-11 表 3-12 结果表明：本文所改进的模型在检测虫蚀粒与破损粒的过程中有着

优越的性能。

本文通过对验证集的检测对比各个算法之间的漏检率。验证集中包含 20 粒的图像。图 3-15 为 20 粒的预测结果图片，对比结果如下。

其中，本文所提出算法 IDS-YOLO 在 20 粒的验证实验中无漏检，YOLOV8-S 算法漏检了 1 粒，YOLOV10-S 与 YOLOV7-Tiny 漏检 2 粒，SSD 与 Mobilenet-YOLOV4 漏检 3 粒。本文为了验证所提出模型的低漏检率，提取了训练集中不存在的 30 粒图像用于检测。

图 3-16 为 30 粒的检测效果对比图。检测结果表明：本文所提出算法 IDS-YOLO 在 30 粒的验证实验中漏检了 1 粒，YOLOV8-S 算法漏检了 3 粒，并且本文所改进算法的参数为 YOLOV8-S 模型参数的二分之一。其余对比的轻量化算法漏检范围在 4~6 粒之间。




图 3-16 本文所改进模型与其他模型在 30 粒测试集中的检测效果

由于粮食无人机以及其他粮面检测设备在粮仓内部进行检测时往往受到多种情况的影响：光照强度、拍摄的倾斜度。为此，本文使用不同的粮面检测设备对实时检测中所遇到不同情况进行采集，采集图像作为验证集，以验证所提出算法的有效性。图 3-17 为光照较暗情况下本文提出算法与其他算法的检测效果对比。




图 3-17 光照较暗情况下本文提出算法与其他算法的检测效果对比




图 3-18 角度倾斜情况下本文提出算法与其他算法的检测效果对比

图 3-18 为倾斜角度拍摄图像的检测效果对比。图 3-17 中图像中的不完善颗粒为

20 粒,在光照条件恶劣的情况下,本文改进算法 IDS-YOLO 漏检 1 粒,YOLOV8-S 与 YOLOV10-S 漏检 2 粒,其余对比算法漏检范围在 3~8 粒。图 3-18 中倾斜角度拍摄图像中不完善颗粒为 21 粒,在镜头倾斜时捕捉到了新的不完善颗粒;IDS-YOLO 漏检 1 粒,YOLOV10-S、YOLOV8-S 漏检 2 粒,其余轻量化对比算法漏检范围在 3~4 粒。

由不同环境的检测效果可以得出,本文提出的改进算法模型虽然可以对不良光照环境和倾斜角度的图像有着良好的识别效果,但是模型依旧需要进一步改进以应对更多在实时检测中发生的各种情况。

3.6 本章小结

本文提出了一种基于 YOLOV4-Tiny 算法的改进模型。为了提升模型的实时检测能力与硬件部署的方便性,本文使用深度分离卷积的方式对参数进行了轻量化,使得模型整体的参数减少。由于本文的检测背景为密集的小麦颗粒,为了使模型对小目标具有更低的漏检率,添加了小目标检测头。在模型轻量化的同时兼顾检测的精确度,本文在特征融合通道中加入改进的通道注意力机制 SENet。改进后的模型大小仅为 5.51 M,图像处理速度为 88 帧/s,满足实时检测的要求。检测“Broken Kernel”和“Injured Kernel”的平均精度分别为 95.92%、98.67%。通过与文中其他算法对比可知,改进后的 IDS-YOLO 不仅具有良好的特征提取能力,并且模型体积小、精度高,满足高大平方仓中粮食无人机的部署与实时检测要求。

4 基于 Feature-GAN 的储麦品质数据扩容方法

4.1 引言

在深度学习中,数据增强扮演着至关重要的角色,尤其是在处理稀缺且难以获得的数据时。关于粮食品质的预测,数据采集通常需要大量的时间,并依赖于昂贵的测量设备和专业人员进行精确的测试与记录。因此,关于储粮品质的数据通常极为有限,这给深度学习模型的训练带来了较大的困难。

在这种情况下,数据增容方法提供了有效的解决方案,通过现有数据,能够生成多样化的训练样本,从而有效地扩展数据集。一方面能够解决数据量不足的问题,另一方面还能够增强模型优化的能力。此外,通过数据增容,可以模拟不同的场景和条件,从而处理实时数据更加具有稳定性,并提高预测结果在实际应用中的准确性和稳定性。通过数据增强,可以在样本有限的情况下,获得更多有效的训练数据,使模型能够更好地学习数据中的潜在规律。因此,扩充后的数据不仅提升了预测模型的性能,还为解决数据稀缺的瓶颈提供了有效的途径,进而提高了储麦生理生化指标预测的精度。

小麦在储藏初期阶段(0~20d),小麦籽粒内部进行着复杂的自身呼吸作用^[67],但由于小麦的“后成熟”特性,在生理后熟期(40~50d),储麦生理生化指标均有显著改变^[68]。针对储麦生理生化指标数据稀缺问题,本章对生成对抗网络进行优化,完成储麦初期生理生化指标扩容任务。

4.2 生成对抗网络模型

生成对抗网络(Generative Adversarial Network, GAN)作为深度学习领域的创新架构,其核心由生成模块(Generative Model, G)与判别模块(Discriminative Model, D)构成动态双系统。模型框架如图 4-1 所示,生成器 G 负责构建合成样本空间,判别器 D 则通过概率评估机制区分真实数据分布与生成数据特征。两者通过对抗性训练形成动态博弈过程,最终驱动生成模块输出高质量数据。在生成对抗网络模型的训练过程中,通过判别结果的真伪,计算生成器和判别器相应的损失函数 $\text{Loss}(G)$ 和 $\text{Loss}(D)$,优化生成器生成数据质量和判别器判别标准,以此往复循环生成更高质量的样本并达

到纳什均衡。




图 4-1 生成对抗网络结构图

GAN 网络在对抗过程中的目标函数为：

$$\min_G \min_D V(G,D) = E_{x \sim p_r} [\ln D(x)] + E_{z \sim p_z} [\ln(1 - D(G(z)))]$$

(4-1)

在表达式中，输入真实数据的 x 分布被表示为 P_r ，生成器输入的随机噪声分布被表示为 P_z ； $D(x)$ 为判别器输出的真实样本，而 $G(z)$ 为生成器输出的生成样本；数学期望的计算过程表示为 E_z 。

生成器的损失函数由式(4-2)表示。式中，输入生成器的随机噪声被表示为 z_i ，数据总量为 N 。

$$G(Loss) = \frac{1}{N} \sum_{i=1}^N \log(D(G(z_i)))$$

(4-2)

判别器的损失函数由式(4-3)表示。式中， x_i 为输入的真实数据。

$$D(Loss) = -\frac{1}{N} \sum_{i=1}^N [\log D(x_i) + \log(1 - D(G(z_i)))]$$

(4-3)

根据生成器与判别器的损失可得出 GAN 网络模型在博弈过程中的对抗损失函数为：

$$L_{Gan}(G,D) = G(Loss) + D(Loss)$$

(4-4)

传统的 GAN 算法虽然可以解决现有数据量稀少的问题，但生成器在生成数据之前是依据输入随机噪声的相应特征来产生数据。因此，传统 GAN 算法在输出的数据中常常面临着产生数据类型单一，数据范围分布狭窄以及产生数据与真实数据分布特征差异过大的问题。

4.3 生成对抗网络模型的优化

4.3.1 生成器优化

基础的生成对抗网络模型在特定需求情况下输出数据的特征分布与真实数据分布差异过大，本文设计原数据特征自编码提取器，通过对真实数据耦合特征与时序特征的提取，并将特征与随机噪声进行拼接，以此来控制数据生成方向并产生符合目标域指定的小麦理化指标数据样本。改进后的 GAN 模型结果如图 4-2 所示。




图 4-2 本文提出 Feature-GAN 网络模型结构

根据网络结构图所示，生成器的输入为随机噪声和特征 c 的混合输入。小麦理化指标原数据由温度、湿度以及电导率等数据构成，小麦理化指标参数表示如公式(4-5)所示。其中， X 为小麦理化指标数据所构成的矩阵， $x(i_1, j_1, t_1)$ 表示，小麦在不同温度 i 、湿度 j 的环境中，在时序 t 时刻的储藏状态。

$$X = [x(i_1, j_1, t_1) \quad x(i_2, j_2, t_2) \quad \dots \quad x(i_n, j_n, t_n)] \tag{4-5}$$

通过采用编码器原数据的特征提取方法，降维过程如公式(4-6)所示。通过对原数据的降低维度信息得到具有同一量纲的数据。

$$c = E(X, \delta) \tag{4-6}$$

其中， E 为编码器， δ 表示编码器的参数， c 表示原始数据经编码器处理后映射到低维空间的特征。数据生成过程如公式(4-7)所示：

$$Y = G(z_{con}(c, z), \theta) \tag{4-7}$$

其中, Y 为生成数据, θ 为生成器相关参数, z_{con} 表示将低维特征与输入生成器中的噪声 z 进行拼接用以生成数据。生成数据的产生过程经过优化后, 生成器的损失函数也会包含与低维特征拼接而成的随机噪声 z_{con} , 其公式如(4-8)所示:

$$G(Loss) = \frac{1}{N} \sum_{i=1}^N \log(D(G(z_{con}))) \quad (4-8)$$

4.3.2 判别器优化

小麦在储藏过程中的指标参数包含多个量纲: 温度的单位为摄氏度, 湿度与水分的单位都为百分比, 其余的指标单位意义均不相同。除此之外, 不同的指标数据范围差异过大。为了提取理化指标的特征, 需要控制不同指标在同一纬度的基础上进行数据特征提取。核 PCA 方法 (KPCA) 具有非线性数据特征的提取能力, 首先确定高斯核函数将生成数据与原始数据映射至高维空间, 方便提取数据间非线性关系, 映射过程如公式(4-9)所示:

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2) \quad (4-9)$$

其中, x_i, x_j 为数据点位, γ 为控制映射强度的核参数。使用 KPCA 进行特征提取目的为构建特征匹配损失, 因此需要将真实数据与生成数据的特征配对。对真实数据 $X = \{x_1, x_2, \dots, x_n\}$ 与生成数据 $Y = \{y_1, y_2, \dots, y_m\}$ 分别构建核矩阵, 并进行去中心化消除偏差值的影响, 核矩阵构成及中心化过程如公式(4-10)、(4-11)所示:

$$\tilde{K}(x_i, x_j) = K(x_i, x_j) - \frac{1}{n} \sum_{k=1}^n K(x_i, x_k) - \frac{1}{n} \sum_{k=1}^n K(x_k, x_j) + \frac{1}{n^2} \sum_{k=1}^n \sum_{l=1}^n K(x_k, x_l) \quad (4-10)$$

$$\tilde{K}(y_i, y_j) = K(y_i, y_j) - \frac{1}{n} \sum_{k=1}^n K(y_i, y_k) - \frac{1}{n} \sum_{k=1}^n K(y_k, y_j) + \frac{1}{n^2} \sum_{k=1}^n \sum_{l=1}^n K(y_k, y_l) \quad (4-11)$$

式中第一项为原始矩阵元素, 第二项与第三项为去除矩阵中 i 行 j 列的偏移均值, 最后一项需要填补重复消除的全局均值, 以保证矩阵的完整性。在此基础上对核矩阵取特征值并进行主成分投影操作, 过程如公式(4-12)所示:

$$\tilde{K}_z \alpha_k = \lambda_k \alpha_k \quad (Z \in (X | Y), k = 1, 2, 3 \dots n) \quad (4-12)$$

其中 λ_k 为第 k 个特征值, α_k 为其相对应的特征向量, 并且满足归一化条件, 此公式中将真实数据与生成数据联合表示。特征值分解完成, 原始数据和生成数据的前 k 个主成分构成的特征向量如公式(4-13)、(4-14)所示:

$$F(x_{i,j})=[f_1(x_{i,j}),f_2(x_{i,j}),\cdots,f_k(x_{i,j})] \tag{4-13}$$

$$F(y_{i,j})=[f_1(y_{i,j}),f_2(y_{i,j}),\cdots,f_k(y_{i,j})] \tag{4-14}$$

判别器通过比较 $F(x_{i,j})$ 与 $F(y_{i,j})$ 的分布差异并结合判别器的对抗损失，组成联合损失函数，损失函数公式为：

$$D(Loss)=-\frac{1}{N}\sum_{i=1}^N[\log D(x_i)+\log(1-D(G(z_i)))]+\beta\cdot\|F_{KPCA}(x)-F_{KPCA}(y)\|_F^2 \tag{4-15}$$

其中， β 为权重系数，控制判别过程中原始数据分布的重要程度，使生成数据的特征分布与原始数据相似。

4.4 储麦品质数据预处理

本文所采用的小麦生理生化指标数据来自河南瑞星有限公司的瑞星 1 号，通过对不同筒仓以及仓内不同储藏区域进行采集，得到小麦籽粒的环境数据和理化指标数据。所得到数据包含的指标有十二个，但其中有些指标与相应的环境参数相关性不强。




图 4-3 相关性矩阵构图

为了提高模型的预测能力，需要对数据进行分析并得出输入变量与输出变量的相

关性,排除输入量与输出量之间弱相关性,进而提升模型训练效果。由于小麦数据为非正态分布状态,为了避免分布假设和异常值干扰,本文采用斯皮尔曼法检验各个生理生化指标的相关性。斯皮尔曼相关系数的计算公式为:

$$R_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)} \quad (4-16)$$

R_s 为斯皮尔曼相关系数,范围在[0,1]之间。 d_i 代表着第 i 个数据点位在 XY 两个变量的排名差异。 n 为数据量。通过计算各个指标之间的斯皮尔曼相关系数,绘制小麦生理生化指标相关性矩阵图。所选取的生理生化指标包括:温度、湿度、电导率、淀粉、蛋白质、水分等十二项数据,各指标间的相关性矩阵图如图 4-3 所示。

4.5 储麦品质数据增容结果分析

4.5.1 储麦品质数据相关性评估标准

根据本文的技术路线,完成迁移学习的前提为构造小麦生理生化指标的源域数据库,并且源域数据库与目标域数据库的数据应有相似特征分布。为了评估 Feature-GAN 模型生成数据的质量,本节需要对生成样本和原始样本的数据特征进行比较。

首先,本节通过增容数据和原始数据之间的概率分布、数据特征距离以及数据特征向量方向三个方面对比,全面的评估了增容数据的质量优劣性,也评估增容数据与原始数据的相关性。概率分布通过 KL 散度检验,其公式如(4-17)所示。

$$D_{KL}(P \parallel Q) = \sum_x P(x) \log \frac{P(x)}{Q(x)} \quad (4-17)$$

KL 散度将增容数据与原始数据转化为概率分布 $P(x)$ 、 $Q(x)$, 检验两组数据在信息量上的分布差异。KL 散度值越小,说明增容数据和原始数据之间分布差异性越小,证明数据在增容的过程中并没有产生过多的偏差,原始数据的总体特征在增容过程中得到了保留。

数据特征距离通过距离相关系数 (Distance Correlation) 进行检验,该系数可提取增容数据与原始数据的非线性关系。检验过程如公式(4-18)所示。

$$dCor(X, Y) = \frac{dCov(X, Y)}{\sqrt{dCov(X, X) \cdot dCov(Y, Y)}} \quad (4-18)$$

距离相关系数的取值范围为[0,1], 值越大证明增容数据与原始数据具有相关性, 根据计算结果评估增容数据对原始数据内在结构关系的保留效果, 距离相关系数的计算结果直观的表示出量化后两组数据之间的相关性。

数据特征向量通过余弦相似度 (Cosine Similarity) 检验, 计算过程如公式(4-19)所示。

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$

(4-19)

小麦生理生化指标数据中各个指标的维度等级不同, 余弦相似度专注于评估向量方向的一致性, 不受向量维度的影响。余弦相似度的计算结果在范围[-1, 1]之间, 数值趋近 1 时表示向量方向趋于同向, 数值趋向-1 时表明向量方向偏移度较大。通过以上方法对比增容数据与原数据之间的关系, 可以从多个角度详尽的检验增容数据的质量与原数据的特征相似性, GAN 网络和 Feature-GAN 网络生成数据的各项指标对比如表 4-1 所示。

表 4-1 GAN 与 Feature-GAN 生成数据指标对比

生理生化指标	GAN			Feature-GAN		
	KL 散度	距离相关系数	余弦相似度	KL 散度	距离相关系数	余弦相似度
水分	0.0164	0.328	0.7010	0.0048	0.725	0.9592
蛋白质	0.0089	0.108	0.5290	0.0016	0.804	0.9613
电导率	0.0109	0.221	0.6419	0.0034	0.873	0.9605
脂肪酸值	0.2195	0.095	0.6591	0.0014	0.719	0.9587
平均值	0.0639	0.188	0.6327	0.0028	0.78	0.96

根据表中检验结果所示。Feature-GAN 增容数据的 KL 散度值比 GAN 的增容数据的值小 0.0611, 表明 Feature-GAN 生成的数据在概率分布方面与原数据更相似。在余弦相似度方面, Feature-GAN 增容的四项指标与原数据的相似度均达到 0.9 以上, 而 GAN 网络的相似度均低于 Feature-GAN 网络的相似度, 表明 Feature-GAN 在生成数据的过程中充分的学习了原始数据的特征。

4.5.2 数据相关性可视化

原始数据的获取通过对储藏过程中的小麦定期扦样获取, 并对小麦的生理生化指

标以固定的间隔天数测量，原始数据中小麦生理生化指标具有一定的连贯性，保证了原始数据集的质量。因此，需要对增容数据构成的数据集进行评估，对比数据特征分布的主要方法有T分布随机近邻嵌入(T-distribution stochasticneighbour embedding, T-SNE)、主成分分析、线性判别分析等。小麦生理生化指标数据由高低不同维度的数据构成，因此需要可以处理高维度非线性数据的 T-SNE 法处理数据并绘制生成的生理生化指标样本和原始样本的分布情况并进行对比。绘制对比图如图 4-4 所示。




图 4-4 生成数据与原始数据 T-SNE 可视化对比

对比图直观的表示出原始数据与生成数据的特征分布与近似程度。通过 T-SNE 对比图，可以观察到 Feature-GAN 网络生成的数据与原始数据的分布区域相仿，有着良好的重叠层度。通过观察非重叠区域，发现生成数据也弥补了原始样本分布之外的更多特征分布。

4.6 本章小结

小麦在储藏过程中，小麦的质量与生理生化指标的变化有所关联，本章探讨了由于储麦生理生化指标的检测现状造成了样本稀少的问题。通过总结小麦生理生化指标在储藏过程中随时间、温度、湿度的变化趋势，更为全面的了解到储麦生理生化指标的变化规律。

本章通过对基础生成对抗网络的数据生成过程进行分析，发现基础生成对抗网络在生成数据的过程中由于随机噪声的不确定性会产生单一范围数据以及数据分布不均匀的问题。为此，本章提出了基于原数据特征提取的生成对抗网络 Feature-GAN。改进后的 Feature-GAN 网络首先对原始数据的特征进行提取，并将原始数据的特征向量与随机噪声合并作为生成器的输入，解决了生成数据与原始数据分布差异过大的问题。通过分析生成器与判别器的工作原理，将原始数据的特征转换为判别器判别过程中的条件，优化判别器的判别结果。基于上述工作，优化后的 Feature-GAN 网络生成了高质量的增容数据。

本章结尾，分别对 GAN 和 Feature-GAN 网络产生的增容数据在概率分布、数据相似性、特征向量三个方面全面对比。根据对比结果，改进后的 Feature-GAN 所产生的增容数据与原数据有着较高的相似度，提高了后续预测工作的效率与准确度。

5 基于迁移学习和改进淘金热算法优化 LSTM 的生理生化指标预测方法

5.1 引言

随着人工智能和深度学习技术的迅猛发展，长短期记忆网络（Long Short-Term Memory, LSTM）作为循环神经网络的改进型架构，这种具有记忆单元和门控单元的协同工作机制，使 LSTM 能够动态调节信息流，显著提升处理长时序数据的能力，并有效解决了传统 RNN 存在的梯度消失问题。但 LSTM 预测准确性与其参数设定具有极强的关联性^[69]，例如 LSTM 训练过程中数据批量设置较大，虽然提高了训练效率，但容易使模型趋向局部最优解。并且，通过增加隐藏层维度可以更好的表征数据间的时序关联使模型的预测精度提高，因此模型参数的优化决定了预测精度。智能优化算法的引入使模型可以更好的收敛于最优解，提高模型的训练效率和准确性。淘金热优化算法^[70]其原理为基于淘金者相互协作寻找最佳金矿位置，在搜索阶段淘金者会以信息沟通的方式寻找最优解，但由于其在发现潜在最优解时就进行挖掘，因此极易陷入局部最优解^[71]。

在数据稀缺的领域中应用迁移学习进行知识迁移，已成为提高模型预测能力的解决方法之一。在农业技术领域，柑橘的缺陷检测由于其数据集缺少，针对此问题，贾惠^[72]等通过使用旋转、高斯模糊等方法对原始数据集进行增强扩容，并使用基于特征模型的方法将源域特征嫁接于目标域，并将样本数量分为七个量级进行比较，实验证明在经迁移学习优化后，模型的预测能力、泛化能力、收敛能力均高于未优化模型。

本章提出基于迁移学习对储麦指标特征复用与改进淘金者优化算法的 LSTM 方法，实现储麦生理生化指标变化趋势的预测。

5.2 基于迁移学习的储麦生理生化指标预测方法

5.2.1 长短期记忆网络

相较于 RNN，LSTM 深度发掘了数据在时序上的关联。在本文的实验背景中，小

麦的生理生化指标会随时间以及储藏环境耦合的情况产生改变，时间对于本文所研究的生理生化指标为强相关因素。LSTM 通过引入门控机制，能够有效地捕获序列数据中的长期依赖关系，其结构如图 5-1 所示，并且结合历史信息与当前的生理生化指标数值，提取生理生化指标变化的时间特征。




图 5-1 LSTM 单元结构图

记忆单元是 LSTM 最关键的组成部分，记忆单元由两个状态构成，分别为一个隐藏状态和一个输出状态。记忆单元的存在帮助 LSTM 能够储存和传输数据信息，有利于网络在处理长序列数据时更有效的记忆和使用之前的数据信息。对于数据信息的流动处理，LSTM 使用三个门控结构来处理。这三个门分别为：遗忘门、输入门、输出门。

（1）遗忘门：此模块具体功能为决定在当前时间是否要删除记忆单元中部分信息。此模块中所含的函数为 Sigmoid，该函数的取值范围为[0,1]之间，根据上一时刻和当前时刻的信息选择消除部分信息。这部分的操作具象为数学公式可以表示为(5-1)：

$$f_t = \mu(W_f x_t + U_f h_{t-1} + b_f) \tag{5-1}$$

其中， t 、 $t-1$ 分别为当前时刻和上一时刻， U_f 、 W_f 为表示遗忘门状态的参数， b_f 表示偏置。 μ 表示激活函数； x_t 表示当前时刻的输入； h_{t-1} 表示上一时刻隐藏层的输入。

（2）输入门：此模块的作用为根据此刻输入信息和上一时刻的记忆信息决定增添部分信息到记忆单元中。增添信息的操作主要依赖于 Sigmoid 和 Tanh 这两个激活函数。

$$i_t = \mu(W_i x_t + U_i h_{t-1} + b_i) \tag{5-2}$$

U_i 、 W_i 为输入门的参数， b_i 表示输入门偏置。 μ 表示激活函数； x_t 表示当前时刻的输入； h_{t-1} 表示上一时刻隐藏层的输入。

在输入门中还需要更新候选值状态，候选值用于更新长期记忆链，候选值公式表示为式(5-3)：

$$\tilde{C}_t = \text{tanh}(W_c x_t + U_c h_{t-1} + b_c) \quad (5-3)$$

LSTM 与传统 RNN 相比较，增添了单元状态更新链，是 LSTM 的关键部分。此模块可以在网络处理时序数据时决定利用过去的有效信息。单元状态从数学维度上分析，与隐藏状态一致，并且被时时更新和传递到下一时刻。其计算方式如公式(5-4)所示。

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (5-4)$$

其中， C_t 、 C_{t-1} 分别为此时刻与上一时刻记忆单元的内部状态， f_t 、 i_t 分别为遗忘门和输入门， $\tilde{C}_t$ 为当前时刻更新的状态。

(3) 输出门：此模块的功能为决定当前时刻哪些信息可以从记忆单元输出到下一时刻，判别信息是否可以输出的函数为 Sigmoid，计算方式如公式(5-5)所示。

$$O_t = \mu(W_o x_t + U_o h_{t-1} + b_o) \quad (5-5)$$

O_t 表示输出门输出的信息。 U_o 、 W_o 为输出门的参数， b_o 表示输出门偏置。 h_{t-1} 表示上一时刻隐藏层的输出。隐藏层的输出由 O_t 和 C_t 共同决定，其计算公式如下所示：

$$h_t = O_t \times \tanh(C_t) \quad (5-6)$$

通过 Tanh 激活函数对 C_t 进行处理，得到与输出门 O_t 相乘的信息与隐藏层的输出 h_t 。

5.2.2 储麦生理生化指标的特征复用

迁移学习是一种通过迁移机制实现不同域间参数共享的机器学习方法，在多个领域有着贡献。在本文的实验背景中，小麦生理生化指标的数据稀少并且难以获取。将迁移学习融入到小麦生理生化指标预测任务中，会极大的减少因数据稀少所带来的影响。

迁移学习与 Feature-GAN 网络以及预测网络 LSTM 的工作内容如图 5-2 所示。本文上述通过对 GAN 模型的改进，使 Feature-GAN 模型生成了大量高质量数据集，并在概率分布、特征向量以及数据相似性三个方面与原始数据相似。因此生成数据具有数

据量多、与目标域数据相似的特性，因此将 Feature-GAN 生成的数据作为迁移学习中的源域数据。并且使用基础的 LSTM 时序预测网络对源域的数据进行训练，与后续目标域训练的基础模型一致。本文源域与目标域的训练任务具有相似性，在源域训练结束后导出 LSTM 的偏置参数模型并冻结，以此作为后续目标域的预训练权重模型。




图 5-2 迁移学习框架

5.3 迁移学习效果分析

5.3.1 实验环境

经上述分析，本文使用扩容后的小麦生理生化指标参数作为迁移学习过程中的源域数据，并在 LSTM 模型中训练模型最优参数，训练环境及配置如表 5-1 所示，在获得最优预训练权重后导出为预训练模型。

表 5-1 实验环境参数

设备	配置
CPU	Intel(R) Core(TM) i7-7700HQ, CPU/2.80GHz
GPU	Nvidia GeForce GTX 1050Ti
Pytorch Framework	Pycharm 2021,Torch 1.51
Accelerated Environment	CUDA 10.1

5.3.2 预训练模型选取

以不同批次的储麦生理生化指标进行训练，训练轮次设置为 300，初始学习率为 0.01，LSTM 的网络层数设置为 3 层。对比不同迁移学习策略对模型训练效果的影响，得出最优的预训练模型。由于本文源域任务与目标域任务相似程度较高，因此迁移学习策略为冻结不同层数的参数导入到目标域任务中。表 5-2 为使用不同迁移策略的模型平均误差对比。

表 5-2 不同迁移学习策略平均误差对比

训练策略	平均误差/%				
	水分	蛋白质	电导率	脂肪酸值	误差平均值
冻结第一层网络	4.62	3.83	2.53	2.85	3.45
冻结前两层网络	3.41	3.35	1.84	2.31	2.72
冻结全部网络	3.89	4.37	3.05	3.71	3.75
不冻结网络	4.40	5.62	4.33	3.24	4.39

迁移学习的策略如表中所示，将预训练模型直接导入目标域进行训练，目标域和源域任务虽然相似，但仍有些非相似之处。因此非解冻的预训练模型无法更新目标域任务的相关训练参数，导致训练结果的平均误差较大。对预训练模型只保留第一层，后两层用于目标域任务训练并对参数进行调整的策略，由于对于源域任务特征复用较少，因此在预测水分蛋白质的任务中误差仍然较大。在保留前两层并对最后一层参数进行微调的策略中，由于对源域参数的充分应用并且更新目标域任务的参数，训练平均误差相对其他策略较低，因此本文在后续的预测任务中都将应用此种迁移学习策略。

5.3.3 实验结果分析

为了更好的验证迁移学习对小麦生理生化指标预测的提升，本章中进行训练的数据与参与数据增容的数据为不同批次的数据。LSTM 基础模型和基于迁移学习的 TL-LSTM 模型的训练对比如图 5-3 所示。

如图所示，在水分、蛋白质、电导率、脂肪酸值四个指标的预测工作中，橙色的曲线为 LSTM 的预测结果，绿色曲线为 TL-LSTM 的预测结果。两组结果与真实数据相比，LSTM 在训练时由于数据稀少的问题导致模型无法学习到生理生化指标在变化时

的特征，因此训练结果与真实数据的差异过大。而 TL-LSTM 由于加入了预训练模型，使模型在训练之前从预训练模型中获取了生理生化指标变化的通用特征。因此 TL-LSTM 的训练结果与 LSTM 相比误差进一步降低。在有了预训模型的基础上，即使数据量较少，也可以避免稀少数据量导致的过拟合问题，同时也提高了训练的效率。




图 5-3 LSTM 与 TL-LSTM 的预测曲线

5.4 基于改进淘金热优化算法的 LSTM 模型

5.4.1 淘金热(GRO)优化算法

淘金热算法（Gold Rush Optimizer, GRO）是一种模拟淘金者协作发现黄金的优化算法，其具体的优化过程如图 5-4 所示。

具体步骤为：

（1）初始化淘金者：随机生成淘金者，淘金者代表着算法中的寻找因子，每个淘金者的位置可以表示为 X_i ， $i=1,2,3...,n$ 。

（2）评估适应度函数：通过对淘金位置的计算，评估每个淘金者位置是否为最优。数学计算式可表示为： $f(X_i)$ 。

(3) 淘金者的位置迁移：根据金矿的位置，淘金者进行位置迁移，迁移操作可由式(5-7)、(5-8)表达。




图 5-4 淘金者优化算法寻优结构

$$\vec{D}_1 = \vec{C}_1 \vec{X}^*(t) - \vec{X}_i(t) \tag{5-7}$$

$$\vec{X}_{new,t}(t+1) = \vec{X}_i(t) + \vec{A}_1 \cdot \vec{D}_1 \tag{5-8}$$

$\vec{X}^*(t)$ 表示最佳金矿的位置， $\vec{D}_1$ 表示淘金者当前时刻与最佳金矿的距离， $\vec{A}_1$ ， $\vec{C}_1$ 是表达控制淘金者移动方向和步长的随机因子，表达式如(5-9)、(5-10)所示。 $\vec{X}_{new,t}(t+1)$ 表示在 $t+1$ 时刻淘金者出现的位置。

$$\vec{A}_1 = 1 + l_1 \left(\vec{r}_1 - \frac{1}{2} \right) \tag{5-9}$$

$$\vec{C}_1 = 2\vec{r}_2 \quad (5-10)$$

(4) 淘金工作：淘金者到达最佳位置开始淘金的搜索工作，通过搜索工作寻找到更好的解。寻找最优解的过程可以由公式(5-12)表示。

$$\vec{D}_2 = \vec{X}_i(t) - \vec{X}_r(t) \quad (5-11)$$

$$\vec{X}_{new,i}(t+1) = \vec{X}_r(t) + \vec{A}_2 \cdot \vec{D}_2 \quad (5-12)$$

$$\vec{A}_2 = 2l_2\vec{r}_1 - l_2 \quad (5-13)$$

根据计算式可得： $\vec{X}_r$ 是另一个随机选择的淘金者， $\vec{D}_2$ 表示当前淘金者与随机选择淘金者的距离， $\vec{A}_2$ 表示控制淘金者移动的方向向量。

(5) 淘金者协作：此步骤随机选择两名淘金者，共享位置信息并重新选取此时刻的搜索区域。该步骤可由式(5-14)、(5-15)表示。其中 $\vec{r}_1$ 是控制淘金者移动方向和距离的随机因子。

$$\vec{D}_3 = \vec{X}_{g2}(t) - \vec{X}_{g1}(t) \quad (5-14)$$

$$\vec{X}_{new,i}(t+1) = \vec{X}_i(t) + \vec{r}_1 \cdot \vec{D}_3 \quad (5-15)$$

(6) 搬迁：在此步骤前，两个随机的淘金者都已发现了金矿，基于此种情况需要淘金者对不同位置的金矿进行评估。在评估过程中，如果当前位置金矿的价值高于其他位置，淘金者金矿就会更新位置信息，否则将停留在原位置。此项步骤可由公式(5-16)表达。

$$\vec{X}_i(t+1) = \vec{X}_{new,i}(t+1) \text{ if } f(\vec{X}_{new,i}(t+1)) < f(\vec{X}_i(t)) \quad (5-16)$$

5.4.2 柯西高斯混合分布

在概率论领域中，柯西分布和高斯分布是重要的连续分布，在提升模型鲁棒性方面有着优越的性能。与正态分布相比，柯西分布有着更为厚重的尾部，因此柯西分布在处理数据中的异常值问题有着更好的鲁棒性。

$$f(x|x_0, \gamma) = \frac{1}{\pi\gamma[1+(\frac{x-x_0}{\gamma})^2]} \quad (5-17)$$

柯西分布如式(5-17)所示,分布的中心位置由位置参数 x_0 所决定,分布的宽度由尺度参数 γ 确定,分布的尾部衰减特性由 $1/x^2$ 所决定,远慢于其他的数学分布。在机器学习模型的训练中,经常会存在模型因局部最优解的困扰而降低性能,而柯西分布由于其独特的重尾特点,生成了大范围的扰动,可以帮助跳出局部最优解的问题。




图 5-5 高斯柯西分布对比

高斯分布的公式如(5-18)所示,与柯西分布相比(对比如图 5-5 所示),高斯分布并不具备重尾特性,均值 μ 决定着对称中心,分布的离散由 σ^2 决定。由于高斯分布的高概率密度在均值附近集中,因此高斯分布适合通过生成微小扰动,缩小搜索范围。

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad (5-18)$$

小麦籽粒作为复杂的有机体,其内部的各项生理变化与外界的环境息息相关,并且各个环境之间也存在着相互影响的关系。因此,小麦生理生化指标的预测需要处理作为输入量的环境参数与作为输出量的生理生化指标参数之间的影响关系,也需要顾及环境参数之间的相互影响,这些因素都将影响网络寻找最佳收敛点的过程。LSTM 在预测过程中,其参数的设置通常由人工设置,这使的在网络训练时会有主观倾向,使设置的参数并不符合网络,导致低效训练。因此本章引入优化算法以帮助网络在训练过程中找到最优解并提升网络对生理生化指标的预测准确度。

5.4.3 淘金热算法的自适应优化

淘金者算法在寻找最优解的过程依赖于淘金者的搜索与交互,但是淘金者在评估最佳位置后会通过搬迁操作移动到新的最佳位置,并且淘金者的寻优范围有限,这些

问题都会导致容易陷入局部最优问题。




图 5-6 TL-CGGRO-LSTM 算法预测流程

因此，本章使用柯西高斯混合分布对淘金热算法进行优化。由于柯西分布的长尾特性可扩大搜索范围，在初始化淘金者时，采用柯西分布进行优化操作。在寻找到全局最优解之后，根据高斯分布具有精细化调整的特性推理得到当前较优解。为了使网络在训练时避免人工设置参数干扰，在柯西高斯混合分布进行的过程中采用自适应动态调整柯西与高斯分布的权重，保证在训练前期采用柯西分布优化，在训练的中后期进行高斯分布优化。自适应调整策略如公式(5-19)表达。

$$\lambda=w_{max}-\frac{t}{T}(w_{max}-w_{min})$$

(5-19)

其中， t 代表当前迭代次数， T 代表总迭代次数。 w_{max} 为初始阶段柯西分布的系数， w_{min} 在训练接近末期时柯西分布的权重下限，此时以局部搜索方法为主但仍保留部分全局更新能力。在引入柯西高斯混合分布扰动的基础上进行淘金者位置的更新，淘金者位置更新过程如式(5-20)所示。

$$x_i^{t+1}=x_i^t+\alpha\cdot[\lambda\cdot N(0,\sigma^2)+(1-\lambda)\cdot C(0,\gamma^2)]$$

(5-20)

x_i^t , x_i^{t+1} 分别表示当前迭代时刻淘金者的位置以及 $t+1$ 次迭代更新后的位置, 可以根据迭代次数动态调整两个分布扰动的权重。 N , C 分别表示高斯分布和柯西分布。 λ 表示自适应权重, 由迭代次数决定使用何种分布, 实现全局搜索向局部搜索过渡, 增强了算法的收敛性。

基于迁移学习与柯西高斯混合分布改进的 TL-CGGRO-LSTM 小麦生理生化指标预测网络模型的实现流程如图 5-6 所示。

5.5 实验结果分析

5.5.1 模型评价指标

本节选取均方根误差 (Root Mean Square Error, RMSE)、决定系数 (Coefficient of Determination, R^2) 和平均绝对误差 (Mean Absolute Error, MAE) 作为评估指标, 以测定小麦生理生化指标预测模型的拟合性能。各指标的计算公式如下所示:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (5-21)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (5-22)$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (5-23)$$

其中 $\bar{y}$ 表示真实值的平均值, y_i 与 $\hat{y}_i$ 分别表示实际值和预测值, n 为数据总量。均方根误差的计算过程需要先取每个插值的平方在此基础上求取这些平方值的平均值, 最后取平方根。与均方误差 (MSE) 相比, RMSE 对离散值以及异常值的敏感性更低, 可以反应出模型之间更全面的性能对比。三个指标中从模型预测值误差、模型性能、模型拟合效果三个方面对比。RMSE 主要对各个模型之间真实值和回归效果的平均相差程度进行对比, MAE 的值越小, 说明模型预测值与实际值的误差越小, 反之值越大说明误差越大。 R^2 指标则表现了模型训练过程中的拟合效果, R^2 的值越小, 表示模型的拟合效果越差, 并且 R^2 指标的参数范围为 $[0,1]$ 。

5.5.2 不同模型训练结果对比

为了验证算法改进的真实性，本文实验所使用的数据批次不同于 TL-LSTM 所使用的数据批次。数据中包含了水分、蛋白质、电导率以及脂肪酸值，将数据导入 TL-CGGRO-LSTM 算法。麻雀优化算法(SSA)、灰狼优化算法(GWO)是与淘金热(GRO)算法类似的群体协作寻找最优值的算法，因此与 TL-CGGRO-LSTM 算法做相同的准备工作，使用 TL-SSA-LSTM、TL-GWO-LSTM 模型与 TL-CGGRO-LSTM 进行对比。为了验证模型改进的有效性，对比算法中添加了 TL-GRO-LSTM。具体的预测对比结果如表 5-3 所示。


表 5-3 不同模型的预测结果对比

生理生化	评价	TL-SSA-LSTM	TL-GWO-LSTM	TL-GRO-LSTM	TL-CGGRO-LSTM
指标	指标				
水分	MAE	0.2778	0.3718	0.1646	0.1299
	R2	0.8717	0.8501	0.9590	0.9686
	RMSE	0.4936	0.5137	0.3106	0.2542
蛋白质	MAE	0.3365	0.4265	0.272	0.1856
	R2	0.7807	0.7703	0.8734	0.9518
	RMSE	0.5531	0.5660	0.4203	0.2092
电导率	MAE	1.7469	2.0457	1.7899	0.9495
	R2	0.8731	0.8598	0.9076	0.9448
	RMSE	2.5886	3.1143	1.2442	0.9013
脂肪酸值	MAE	0.5988	0.7184	0.6787	0.2409
	R2	0.8538	0.8456	0.8737	0.9744
	RMSE	0.8939	0.9771	0.7842	0.3855
平均值	MAE	0.74	0.8906	0.7263	0.3765
	R2	0.8448	0.8314	0.9034	0.9599
	RMSE	1.1323	1.2928	0.6898	0.4376


根据表中模型训练参数可知，在 MAE、R²、RMSE 三个指标参数的对比中，本章节所改进的 TL-CGGRO-LSTM 模型与其他对比模型的实验平均值指标相比，MAE 值

为 0.3765、 R^2 值为 0.9599、RMSE 值为 0.4376。说明了改进后的模型可以满足高拟合效果以及低误差的要求。为了验证改进模型对小麦四项生理生化指标变化趋势的拟合效果，图 5-7 为四项指标预测任务中 TL-CGGRO-LSTM 与对比模型的预测效果。


图中横坐标为储藏天数，由图可知小麦的生理生化指标在由温湿度以及外部环境的耦合作用下，在一些时间段中会出现急剧变化，因此生理生化指标也并非平稳的上升或下降。由图中预测效果的对比可知，TL-CGGRO-LSTM 由于其模型的高拟合性，即使在生理生化指标变化速率较快的情况下，其预测值和真实值较为接近。而其他的对比模型在预测生理生化指标的变化趋势上存在震荡和误差较大情况，也说明了本章节所提出模型在四项生理生化指标预测任务中的可行性。为了进一步说明 TL-CGGRO-LSTM 的低误差率，图 5-8 汇总了 TL-SSA-LSTM、TL-GWO-LSTM、TL-GRO-LSTM、TL-CGGRO-LSTM 四个模型分别在预测四项指标任务中预测值和真实值的误差。




(a)水分



(b)蛋白质



(c)电导率



(d)脂肪酸值

图 5-7 不同模型预测对比

图中紫色和深蓝色分别为 TL-SSA-LSTM、TL-GWO-LSTM 模型的预测误差，通过对比发现，TL-SSA-LSTM、TL-GWO-LSTM 模型误差幅度较大，TL-GRO-LSTM 的预测幅度相对平缓，但误差仍然较大。根据误差结果的对比，TL-SSA-LSTM、TL-GWO-

LSTM、TL-GRO-LSTM 均无法有效完成四项生理生化指标的预测任务。




图 5-8 本文提出算法与对比算法预测效果图

图中亮绿色部分为TL-CGGRO-LSTM模型的预测误差,在四项指标的预测任务中,本文改进算法的误差均要低于其他对比算法。并且在这四项预测任务中,TL-CGGRO-LSTM模型的预测值误差范围几乎都集中于 $[-0.5,0.5]$ 之间,由此证明了本文所改进算法的高拟合性、低误差性以及稳定性。

5.6 本章小结

本章首先对迁移学习的作用进行探讨,得出使用迁移学习策略可改善小麦生理生化指标预测任务中样本稀少的问题。并对上述章节中扩容数据的特点进行分析,并将其作为迁移学习的源域数据。通过对 LSTM、TL-LSTM 的预测效果对比,验证了迁移学习可有效解决小麦生理生化样本稀缺的问题。

为了降低小麦生理生化指标预测任务中的误差,通过对淘金者优化算法的改进,使用了柯西高斯混合分布的优化方法,根据两种分布的不同特点,提出了自适应调整策略,根据训练轮次的数值决定分布的使用。解决了模型在训练过程中过早拟合和陷

入局部最优解的问题。通过 TL-CGGRO-LSTM 模型与其他模型的预测结果对比, TL-CGGRO-LSTM 模型的高拟合性使预测误差相比于其他对比算法更低。平均指标中, MAE 值 0.3765、RMSE 值为 0.4376 表明了改进模型有更低的误差, R^2 值 0.9599 表明了模型的高拟合性。因此 TL-CGGRO-LSTM 在预测四项小麦生理生化指标任务中更具有优越性。

总结与展望

论文总结

本文围绕小麦仓储过程中储麦品质监测需求，从在线检测、样本扩容和生理生化指标预测三个方向进行研究。通过构建多层次的解决方案，有效提升了储粮质量管控能力，为降低储粮品质损耗提供了技术支撑。

(1) 在粮堆表面不完善粒在线检测方面，本文通过融合轻量化网络架构与特征增强策略，设计了兼顾检测精度与速度的深度学习模型。通过引入多层次特征融合机制和注意力优化模块，显著提升了复杂堆叠场景下的颗粒特征辨识能力，同时采用轻量化结构设计，实现了检测效率的优化。实验结果表明，改进后的检测系统在保持实时性的同时，有效降低了传统方法的漏检问题。

(2) 针对生理生化指标样本稀缺的挑战，本文提出基于特征约束的生成对抗网络。通过构建原始数据特征提取器并设计联合损失函数，突破了传统生成模型在数据分布匹配上的局限，实现了与真实指标数据具有高度一致性的样本扩增。该方法为小样本条件下的质量预测提供了可靠的数据基础。

(3) 在生理生化指标动态预测方面，本文构建了融合迁移学习与智能算法优化的长短时预测模型。通过建立跨仓储环境的知识迁移机制，增强了模型对多因素耦合影响的适应能力；引入自适应参数优化策略，有效提升了非平稳时序特征的捕捉精度。实验验证表明，该预测模型能够准确捕捉不同储藏环境下指标的变化规律，为仓储调控决策提供了可靠依据。

本文提出的方法实现了从小麦外观检测到内在指标预测的储藏阶段质量监控，通过深度学习、数据生成模型和时序数据预测的技术结合，显著提升了小麦仓储过程的质量把控能力。研究成果对完善粮食储备智能化管理体系具有重要实践价值，为其他粮食作物的仓储管理提供了可借鉴的技术路径。

论文展望

本文使用深度学习相关技术构建储麦监测方法，实现了粮堆表面不完善粒的在线

检测与储麦生理生化指标变化趋势的预测。还有三个方面需要改进和完善：

（1）在粮堆表面不完善粒的检测任务中，其他粮面检测设备在其移动过程中可能会扬起尘土降低获取图像的质量，未来的工作将继续深入研究检测过程中对于高噪声图像的处理，为提高粮仓自动化管理的效率做出贡献。

（2）小麦籽粒堆叠成为粮堆，因此各个籽粒复杂的自我反应结合具有相应的传热、传湿机制。本文并未对此进行深度的研究，之后工作方向需要结合粮堆各种变化机理进行生理生化指标预测。

（3）小麦籽粒的外形与自身的生理生化指标息息相关，之后的工作可以考虑将籽粒外形检测与生理生化指标预测进行结合，进行更高效的监测。

参考文献

- [1] 宋明. 小麦高产种植技术优化及病虫害的发生与防治措施探讨[J]. 种子世界, 2024(9): 24-26.
- [2] 苏靖. 储藏期内小麦品质评价指标的选择与研究进展[J]. 现代面粉工业, 2021, 35(4): 55.
- [3] 侯胜利. 中国粮食安全的发展历程、现实挑战与提升策略[J]. 农业经济, 2023(12): 32-33.
- [4] 刘雨, 任书炜, 孙倩倩, 等. 小麦籽粒储藏特征挥发物质分析与品质评价[J]. 核农学报, 2024, 38(11): 2155-2164.
- [5] Lin S, Jin X, Gao J, et al. Impact of wheat bran micronization on dough properties and bread quality: Part I – Bran functionality and dough properties[J]. Food Chemistry, 2021, 353: 129407.
- [6] 夏雨杰, 汪静, 陈尚兵, 等. 稻谷储藏过程霉菌挥发性物质和品质分析[J]. 食品工业科技, 2020, 41(8): 90-95.
- [7] 付强, 鞠兴荣, 高瑀珑, 等. 不同储藏条件下小麦粉挥发物与理化指标相关性分析[J]. 粮食储藏, 2012, 41(1): 42-46.
- [8] Fan C. Detection of wheat hardness based on a laser-generated ultrasonic signal[J]. Ukrainian Journal of Physical Optics, 2017, 18(4): 201.
- [9] 张玉荣, 邵帅, 于英威, 等. 蛀蚀性害虫生长繁殖对小麦挥发性成分的影响[J]. 河南工业大学学报(自然科学版), 2019, 40(2): 85-94.
- [10] 郑刚, 孙丽琴. 粮食储存环节储粮损耗产生的原因及解决措施[J]. 现代化农业, 2023(9): 43-45.
- [11] 韩伟, 董朋, 安西友, 等. 粮食仓储损耗原因分析及降耗减损的对策[J]. 粮食与食品工业, 2022, 29(5): 61-64.
- [12] Hamed M A. Impact of Storage Conditions on Seed Vigor and Viability of Bread Wheat (*Triticum aestivum*) seeds[J]. IOP Conference Series: Earth and Environmental Science, 2021, 761(1): 012069.
- [13] 唐金霞. 小麦种植技术及病虫害防治研究[J]. 棉花科学, 2024, 46(2): 79-81.
- [14] 黄宗文, 吕建华, 郭亚飞, 等. 储粮环境挥发性化合物与储粮害虫的关系研究进展[J]. 环境昆虫学报, 2022, 44(1): 74-83.
- [15] 陈二虎, 陈艳, 张琪, 等. 基于 CO_2 释放速率的锈赤扁谷盗虫口密度预测模型构建[J]. 中国粮油学报, 2024, 39(12): 34-39.
- [16] Walters C. Understanding the mechanisms and kinetics of seed aging[J]. Seed Science Research, 1998, 8(2): 223-244.
- [17] 韦志彦, 王金水, 张艳, 等. 新收获小麦后熟过程中蛋白质和氨基酸含量的变化[J]. 中国粮油学报, 2010, 25(2): 23-30.
- [18] 李慧;洪习文;王争艳;王艳艳; 粮食气味物质的提取、关键组分判别及其在储藏中的应用研究进展[J]. 食品科学, 2025, 46(01): 266-273.
- [19] 王若兰, 严佳, 李燕羽, 等. 不同条件下小麦呼吸速率变化的研究[J]. 河南工业大学学报(自然科学版), 2009, 30(4): 12-16.
- [20] 张玉荣, 张晓, 田甜, 等. 加速陈化过程中小麦品质变化及陈化指标筛选[J]. 河南工业大学学报(自然科学版), 2020, 41(5): 91-97.
- [21] 王洪波, 唐昊, 胡洋山, 等. 基于 RIL 群体的小麦籽粒性状与品质特性关系分析[J]. 麦类作物学报, 2017, 37(9): 1155-1160.
- [22] Zayas I, Pomeranz Y, Lai F S. Discrimination between Arthur and Arkan wheats by image analysis[J]. Cereal Chemistry, 1985, 62(6): 478-480.
- [23] Neuman M, Sapirstein H D, Shwedyk E, et al. Discrimination of wheat class and variety by digital

- image analysis of whole grain samples[J]. Journal of Cereal Science, 1987, 6(2): 125-132.
- [24] Paliwal J, Visen N S, Jayas D S, et al. Cereal Grain and Dockage Identification using Machine Vision[J]. Biosystems Engineering, 2003, 85(1): 51-57.
- [25] Liu Z yan, Cheng F, Ying Y bin, et al. Identification of rice seed varieties using neural network[J]. Journal of Zhejiang University-SCIENCE B, 2005, 6(11): 1095-1100.
- [26] 王志军, 丛培盛, 周佳璐, 等. 基于图像处理与人工神经网络的小麦颗粒外观品质评价方法[J]. 农业工程学报, 2007(1): 158-161.
- [27] Choudhary R, Paliwal J, Jayas D S. Classification of cereal grains using wavelet, morphological, colour, and textural features of non-touching kernel images[J]. Biosystems Engineering, 2008, 99(3): 330-337.
- [28] Singh C B, Jayas D S, Paliwal J, et al. Identification of insect-damaged wheat kernels using short-wave near-infrared hyperspectral and digital colour imaging[J]. Computers and Electronics in Agriculture, 2010, 73(2): 118-125.
- [29] 樊超, 夏旭, 石小凤, 等. 基于图像处理的小麦品种分类研究[J]. 河南工业大学学报 (自然科学版), 2011, 32(5): 74-78.
- [30] Pourreza A, Pourreza H, Abbaspour-Fard M H, et al. Identification of nine Iranian wheat seed varieties by textural analysis with image processing[J]. Computers and Electronics in Agriculture, 2012, 83: 102-108.
- [31] 张玉荣, 陈赛赛, 周显青, 等. 基于图像处理和神经网络的小麦不完善粒识别方法研究[J]. 粮油食品科技, 2014, 22(3): 59-63.
- [32] Ebrahimi E, Mollazade K, Babaei S. Toward an automatic wheat purity measuring device: A machine vision-based neural networks-assisted imperialist competitive algorithm approach[J]. Measurement, 2014, 55: 196-205.
- [33] Olgun M, Onarcan A O, Özkan K, et al. Wheat grain classification by using dense SIFT features with SVM classifier[J]. Computers and Electronics in Agriculture, 2016, 122: 185-190.
- [34] Sa I, Ge Z, Dayoub F, et al. DeepFruits: A Fruit Detection System Using Deep Neural Networks[J]. Sensors, 2016, 16(8): 1222.
- [35] 曹婷翠, 何小海, 董德良, 等. 基于 CNN 深度模型的小麦不完善粒识别[J]. 现代计算机 (专业版), 2017(36): 9-14.
- [36] 张思雨, 张秋菊, 李可. 采用机器视觉与自适应卷积神经网络检测花生仁品质[J]. 农业工程学报, 2020, 36(4): 269-277.
- [37] Rong D, Wang H, Xie L, et al. Impurity detection of juglans using deep learning and machine vision[J]. Computers and Electronics in Agriculture, 2020, 178: 105764.
- [38] Zhang W, Ma H, Li X, et al. Imperfect Wheat Grain Recognition Combined with an Attention Mechanism and Residual Network[J]. Applied Sciences, 2021, 11(11): 5139.
- [39] 宋怀波, 王云飞, 段援朝, 等. 基于 YOLO v5-MDC 的重度粘连小麦籽粒检测方法[J]. 农业机械学报, 2022, 53(4): 245-253.
- [40] Zhang D Y, Luo H S, Wang D Y, et al. Assessment of the levels of damage caused by Fusarium head blight in wheat using an improved YoloV5 method[J]. Computers and Electronics in Agriculture, 2022, 198: 107086.
- [41] 吴兰, 周永强. 基于改进 YOLOX 的小麦不完善粒检测技术研究[J]. 河南工业大学学报 (自然科学版), 2023, 44(5): 109-117.
- [42] 马洪娟, 冀定磊, 赵殿仁, 等. 基于 NIRS 的小麦不完善粒精确快速评定方法研究[J]. 中国粮油学报, 2024, 39(12): 195-200.

-
- [43] Qiu Z, Wang F, Wang W, et al. YOLO-SDL: a lightweight wheat grain detection technology based on an improved YOLOv8n model[J]. *Frontiers in Plant Science*, 2024, 15: 1495222.
- [44] 方建军. 粮食水分在线测量的声学方法[J]. *北方工业大学学报*, 2000(1): 57-60.
- [45] García-Álvarez J, Salazar J, Rosell C M. Ultrasonic study of wheat flour properties[J]. *Ultrasonics*, 2011, 51(2): 223-228.
- [46] Marzec A, Cacak-Pietrzak G, Gondek E. MECHANICAL AND ACOUSTIC PROPERTIES OF SPRING WHEAT VERSUS ITS TECHNOLOGICAL QUALITY FACTORS[J]. *Journal of Texture Studies*, 2011, 42(4): 319-329.
- [47] 李广超. 小麦水分声学测定方法的研究[D]. 河南工业大学, 2012.
- [48] 杨梅, 李广. 基于小麦碰撞声音的霉变区域识别仿真分析[J]. *计算机仿真*, 2013, 30(7): 429-432.
- [49] Salimi Khorshidi A, Thandapilly S J, Ames N. Application of low-intensity ultrasound as a rapid, cost-effective tool to wheat screening: A systematic frequency selection[J]. *Journal of Cereal Science*, 2018, 82: 190-197.
- [50] Guo M, Ma Y, Yang X, et al. Detection of damaged wheat kernels using an impact acoustic signal processing technique based on Gaussian modelling and an improved extreme learning machine algorithm[J]. *Biosystems Engineering*, 2019, 184: 37-44.
- [51] 邓淼磊, 陈斯, 李磊, 等. 智能感官技术在储藏小麦品质评价中的研究进展[J]. *中国粮油学报*, 2022, 37(6): 36-44.
- [52] 惠国华, 陈裕泉. 基于随机共振的电子鼻系统构建及在谷物霉变程度检测中的应用[J]. *传感技术学报*, 2011, 24(2): 159-164.
- [53] Huo D, Wu Y, Yang M, et al. Discrimination of Chinese green tea according to varieties and grade levels using artificial nose and tongue based on colorimetric sensor arrays[J]. *Food Chemistry*, 2014, 145: 639-645.
- [54] Barkat E H, Du B, Ren Y, et al. Volatile organic compounds associated with postharvest fungi detected in stored wheat grain[J]. *Australasian Plant Pathology*, 2017, 46(5): 483-492.
- [55] 林振华, 姜水, 张红梅, 等. 基于金属氧化物传感器阵列的小麦霉变程度检测[J]. *传感技术学报*, 2018, 31(7): 1017-1023.
- [56] Wadood S A, Boli G, Xiaowen Z, et al. Geographical discrimination of Chinese winter wheat using volatile compound analysis by HS-SPME/GC-MS coupled with multivariate statistical analysis[J]. *Journal of Mass Spectrometry*, 2020, 55(1): e4453.
- [57] 蒋华伟, 郭陶, 杨震. 基于改进粒子群优化-反向传播神经网络算法的小麦储藏品质预测模型[J]. *科学技术与工程*, 2021, 21(21): 8951-8956.
- [58] Sandhu K S, Lozada D N, Zhang Z, et al. Deep Learning for Predicting Complex Traits in Spring Wheat Breeding Program[J]. *Frontiers in Plant Science*, 2021, 11: 613325.
- [59] Chen D, Liu B. Temperature Prediction for Stored Grain: A Multi- model Fusion Approach Based on Machine Learning[C]. 2024 9th International Conference on Electronic Technology and Information Science (ICETIS). 2024: 661-665.
- [60] Gao H, Zhen T, Li Z. Detection of Wheat Unsound Kernels Based on Improved ResNet[J]. *IEEE Access*, 2022, 10: 20092-20101.
- [61] 李震, 李佳盟, 王楠, 等. 基于轻量化改进模型的小麦白粉病检测装置研发[J]. *农业机械学报*, 2023, 54(S2): 314-322.
- [62] Gai R, Chen N, Yuan H. A detection algorithm for cherry fruits based on the improved YOLO-v4 model[J]. *Neural Computing and Applications*, 2023, 35(19): 13895-13906.
- [63] Zhang D Y, Luo H S, Wang D Y, et al. Assessment of the levels of damage caused by Fusarium head
-

- blight in wheat using an improved YoloV5 method[J]. Computers and Electronics in Agriculture, 2022, 198: 107086.
- [64] Zhang W, Ma H, Li X, et al. Imperfect Wheat Grain Recognition Combined with an Attention Mechanism and Residual Network[J]. Applied Sciences, 2021, 11(11): 5139.
- [65] Zhang D Y, Zhang W, Cheng T, et al. Detection of wheat scab fungus spores utilizing the YOLOv5-ECA-ASFF network structure[J]. Computers and Electronics in Agriculture, 2023, 210: 107953.
- [66] Chen C, Liang Y, Zhou L, et al. An automatic inspection system for pest detection in granaries using YOLOv4[J]. Computers and Electronics in Agriculture, 2022, 201: 107302.
- [67] 胡元森, 田萍萍, 李棒棒, 等. 粮食储藏生理性变质研究进展[J]. 中国粮油学报, 2020, 35(11): 179-186.
- [68] 田奇生, 崔春晓, 张鸿一, 等. 基于生理生化指标的小麦生理后熟期快速判定[J]. 中国粮油学报, 2025, 40(1): 33-42.
- [69] 于珍珍, 邹华芬, 于德水, 等. 基于 SSA-LSTM 的玉米土壤含氧量预测模型[J]. 农业机械学报, 2022, 53(11): 360-368, 411.
- [70] Zolfi K. Gold rush optimizer: A new population-based metaheuristic algorithm[J]. Operations Research and Decisions, 2023, 33(1):113-150.
- [71] 王玲芝, 李晨阳, 刘婧, 等. 基于 GRO-SSA-LSTM 的短期光伏发电功率预测[J]. 太阳能学报, 2025, 46(2): 401-409.
- [72] 贾惠, 伍希志, 薛洋, 等. 基于迁移学习和数据增强的小样本柑橘缺陷检测研究[J]. 农业与技术, 2024, 44(2): 23-27.